

POLYTECHNIQUE MONTRÉAL

affiliée à l'Université de Montréal

**Processus de réponse aux appels d'offres : Intégration de méthodes
d'intelligence artificielle exploitant des données contractuelles et
concurrentielles**

SALAUN ELOUAN

Département de mathématiques et de génie industriel

Mémoire présenté en vue de l'obtention du diplôme de *Maîtrise ès sciences appliquées*

Génie Industriel

Juin 2026

POLYTECHNIQUE MONTRÉAL

affiliée à l'Université de Montréal

Ce mémoire intitulé :

Processus de réponse aux appels d'offres : Intégration de méthodes d'intelligence artificielle exploitant des données contractuelles et concurrentielles

présenté par **Elouan SALAUN**

en vue de l'obtention du diplôme de *Maîtrise ès sciences appliquées*

a été dûment accepté par le jury d'examen constitué de :

Christophe DANJOU, président

Robert PELLERIN, membre et directeur de recherche

Anas NEUMANN, membre et codirecteur de recherche

Mario BOURGAULT, membre

REMERCIEMENTS

Je tiens à adresser mes remerciements les plus sincères à Robert PELLERIN et Anas NEUMANN, en leurs qualités de directeur et de codirecteur de recherche, pour leur encadrement, leur disponibilité et leurs conseils avisés tout au long de ce projet. Leur expertise, leur confiance et leur sympathie ont été déterminantes dans l'aboutissement de ce projet.

Je remercie également Christian VASSEUR pour son accueil, son suivi régulier et son implication dans ce projet. Merci également à Pierre CORBEIL pour mon intégration au sein des équipes et pour son suivi du projet. Aussi, je tiens à remercier toutes les personnes des Commissionnaires du Québec que j'ai eu l'opportunité de rencontrer au cours de ce projet pour leur soutien, leur enthousiasme et leur implication, qui ont particulièrement contribué au bon déroulement de cette expérience.

Enfin, j'aimerais remercier mes collègues de bureau et mes amis pour leur soutien, leurs encouragements et les moments chaleureux, qui ont été une source inestimable de motivation tout au long de mon projet. Je suis extrêmement reconnaissant d'avoir eu l'occasion de partager cette aventure et ces moments précieux avec eux.

Pour conclure, je souhaite remercier chaleureusement ma famille qui m'a soutenu à chaque étape de mon parcours, leur appui constant a été déterminant dans la réussite de ce parcours.

RÉSUMÉ

La réponse aux appels d'offres constitue un mécanisme central d'obtention de contrats et un facteur déterminant de la pérennité de nombreuses organisations. Pour notre partenaire, les Commissionnaires du Québec, un acteur majeur du marché des services de gardiennage avec un revenu annuel de 747 M\$ et plus de 22 millions d'heures de sécurité travaillées en 2025, la majorité des contrats est attribuée par voie d'appels d'offres publics. La qualité du processus de réponse, et plus particulièrement la pertinence de la décision de soumissionner et de la marge proposée, conditionnent directement le taux de succès et la rentabilité de l'organisation.

Bien que ce processus génère des données potentiellement cruciales, celles-ci n'étaient jusqu'alors que peu exploitées. Les décisions reposaient principalement sur les perceptions et les expériences des gestionnaires. La revue de littérature menée dans le cadre de ce mémoire confirme que, si la modélisation tarifaire et la décision de soumission constituent des champs étudiés depuis plusieurs décennies, l'intégration conjointe de l'extraction automatisée d'information textuelle, de l'analyse de similarité entre contrats et de la modélisation tarifaire reste peu documentée. Elles demeurent inexistantes dans le secteur des services de sécurité.

Dans ce contexte, notre recherche vise à améliorer le processus de réponse aux appels d'offres en valorisant les données historiques disponibles. La démarche suit la méthodologie Design Research Methodology (DRM) et s'organise autour de cinq outils complémentaires d'aide à la décision développés en Python : (i) un module d'anticipation des appels d'offres et de fouille historique fondé sur le scraping de la plateforme SEAO et la résolution d'entité pour les contrats passés, (ii) un module de valorisation des données textuelles utilisant une architecture de génération augmentée de récupération (RAG) couplant embeddings creux, hiérarchie documentaire et BM25, (iii) un module de calcul de similarité entre contrats appris par renforcement de classement, (iv) un modèle de tarification de type Learning to Rank intégrant à la fois les caractéristiques techniques des contrats et la dynamique récente du marché, et (v) un outil de visualisation interactif assurant l'intégration de l'ensemble dans le processus métier.

Les outils ont été testés sur un échantillon représentatif d'appels d'offres publiés entre 2023 et 2026. L'algorithme de résolution d'entités atteint un taux de concordance de 92 % pour la récupération des contrats antérieurs. Le modèle de tarification, lorsqu'on se limite aux marges économiquement

viables, se classe dans le top 3 des soumissionnaires dans 70 % des cas et améliore le rang du CCCQ dans 90 % des appels d'offres confrontés à la référence interne. La comparaison avec les décisions historiques sur 20 appels d'offres met en évidence un gain potentiel de profit substantiel, sous réserve d'une lecture experte des recommandations situées sous le seuil de viabilité d'environ 0,3.

Ces outils n'ont pas vocation à se substituer à l'expertise humaine, mais à l'enrichir en lui apportant une vision quantitative, structurée et systématique du contexte de chaque appel d'offres. Ils constituent ainsi un levier d'optimisation des taux de victoire et de la rentabilité, tout en facilitant la prospection et la lecture des devis techniques.

ABSTRACT

For many organizations, responding to public tenders is a central mechanism for winning contracts and a major determinant of their long-term viability. For our partner, the Commissionaires of Quebec (CCCQ), a leading player in the security and guarding services market with annual revenues of CAD 747 M and more than 22 million security hours worked in 2025, most of the contracts are awarded through public tenders. The quality of the response process, and more specifically, the relevance of the bid/no-bid decision and the proposed margin, directly conditions the organization's win rate and profitability.

Although this process generates enough crucial data, it has been weakly leveraged until now. Decisions relied mainly on analysts' experiences and perceptions. The literature review conducted in this thesis confirms that, while bid pricing modelling and bid/no-bid decision-making have been studied for several decades, the joint integration of automated textual information extraction, contract similarity analysis, and bid pricing modelling remains poorly documented and is particularly lacking in the security services sector.

In this context, our research aims to design a decision-support tool that leverages historical data to improve the tender response process. The work follows the Design Research Methodology (DRM) and is organized around five complementary modules developed in Python: (i) An anticipation and historical mining module based on SEAO web scraping and entity matching to anticipate tenders and retrieve similar past ones; (ii) a textual data valorization module relying on a Retrieval-Augmented Generation (RAG) architecture combining sparse embeddings, document hierarchy and BM25; (iii) a contract similarity module trained through ranking-based reinforcement (RankNet); (iv) a Learning-to-Rank pricing model that jointly accounts for the technical characteristics of contracts and recent market dynamics; and (v) an interactive visualization tool ensuring the integration of all components into the business process.

The tool was evaluated on a representative sample of tenders published between 2023 and 2026. The entity-matching algorithm achieves a 92% concordance rate when retrieving previous contracts. The pricing model, when restricted to economically viable margins, ranks in the top 3 bidders in 70% of cases and improves the CCCQ's ranking in 90% of the tenders compared to the internal reference. The comparison with historical decisions on 20 tenders highlights a substantial

potential profit gain, provided that an expert review is conducted of recommendations that fall below the viability threshold of approximately 0.3.

The proposed tool is not intended to replace human expertise, but rather to complement it by providing a quantitative, structured and systematic view of each tender's context. As such, it serves as a lever to optimize win rates and profitability while also facilitating prospecting and reading technical specifications.

TABLE DES MATIÈRES

REMERCIEMENTS	III
RÉSUMÉ.....	IV
ABSTRACT	VI
TABLE DES MATIÈRES	VIII
LISTE DES TABLEAUX.....	XI
LISTE DES FIGURES.....	XII
LISTE DES SIGLES ET ABRÉVIATIONS	XIII
LISTE DES ANNEXES.....	XIV
CHAPITRE 1 INTRODUCTION.....	1
CHAPITRE 2 REVUE DE LITTÉRATURE	3
2.1 Définition des concepts de base	3
2.1.1 Appel d’offres	3
2.1.2 Soumissionnaires.....	4
2.1.3 Stratégie de réponse	4
2.2 Protocole de recherche	4
2.3 Résultats	6
2.3.1 Appels d’offres 4.0	6
2.3.2 Modélisation des décisions et stratégies de soumission des soumissionnaires	8
2.3.3 NLP pour l’extraction d’information contractuelle.....	10
2.3.4 Analyse de risques contractuels par intelligence artificielle	11
2.4 Analyse critique.....	12
2.5 Conclusion.....	14

CHAPITRE 3	MÉTHODOLOGIE DE RECHERCHE.....	16
3.1	Introduction	16
3.2	Objectifs de recherche	16
3.3	Méthodologie de recherche	16
3.4	Conclusion.....	19
CHAPITRE 4	ANALYSE DE L’EXISTANT.....	20
4.1	Présentation du partenaire	20
4.2	Cas d’étude	21
4.2.1	Appels d’offres	21
4.2.2	Contrats	22
4.3	Processus en place aux Commissionnaires	23
4.4	Données disponibles.....	25
4.4.1	Données externes.....	25
4.4.2	Données internes	27
4.4.3	Croisement des données	29
4.5	Conclusion.....	29
CHAPITRE 5	OUTIL ET ÉLÉMENTS PROPOSÉS	30
5.1	Présentation générale de l’outil	30
5.2	Description des modèles et sous-outils intégrés.....	32
5.2.1	Élément 1 : Anticipation et fouille historique	33
5.2.2	Élément 2 : Valorisation des données textuelles.....	34
5.2.3	Élément 3 : Calcul de la similarité des contrats	38
5.2.4	Élément 4 : Modèle de tarification.....	41
5.2.5	Élément 5 : Outil de visualisation	47

5.3	Intégration dans le processus.....	50
5.4	Déploiement	53
5.5	Conclusion.....	53
CHAPITRE 6 EXPÉRIMENTATIONS.....		55
6.1	Appels d’offres utilisés.....	55
6.2	Prospection et anticipation	55
6.3	Analyses	57
6.3.1	Évaluation du modèle de tarification général.....	57
6.3.2	Comparaison avec le comportement de référence des Commissionnaires	59
6.4	Conclusion.....	60
CHAPITRE 7 CONCLUSION ET PERSPECTIVES		62
RÉFÉRENCES.....		66
ANNEXE A PROCESSUS DE RÉPONSE GÉNÉRAL (AS-IS).....		74
ANNEXE B PROCESSUS DE RÉPONSE (AS-IS) PARTIE 1 : PRÉANALYSE		75
ANNEXE C PROCESSUS DE RÉPONSE (AS-IS) PARTIE 2 : ANALYSE.....		76
ANNEXE D PROCESSUS DE RÉPONSE (AS-IS) PARTIE 3 : SCÉNARIO FINANCIER....		77
ANNEXE E MÉTHODE DE RETRIEVAL SPARSE + HIERARCHIE.....		78

LISTE DES TABLEAUX

Tableau 2.1 Concepts clés de la revue de littérature	5
Tableau 2.2 Articles retenus.....	7
Tableau 2.3 Récapitulatif de l'analyse critique.....	14
Tableau 4.1 Données extraites de la plateforme SEAO	27
Tableau 4.2 Variables des caractéristiques techniques des contrats	28
Tableau 5.1 Éléments développés	32
Tableau 5.2 Résultats d'extraction par RAG	37
Tableau 5.3 Variables utilisées pour la similarité des contrats	39
Tableau 5.4 Indices de performance du modèle de tarification	44
Tableau 5.5 Résultat des différents modèles	45
Tableau 6.1 Résultats de couplage par <i>Entity Matching</i>	56
Tableau 6.2 Résultats du modèle pour les AOs de la période 2023-2024	58
Tableau 6.3 Résultat du modèle pour 20 AOs et confrontation avec la référence du CCCQ	61

LISTE DES FIGURES

Figure 2.1 Schéma de la revue de littérature	6
Figure 3.1 Structure de la méthodologie DRM, adaptée de Blessing et Chakrabarti	17
Figure 4.1 Processus de publication d'un AO sur SEO	22
Figure 4.2 Répartition des coûts dans le taux horaire d'un agent (échelle indicative)	23
Figure 4.3 a) Schéma de la récupération des données SEO ; b) Exemple d'une page Web d'AO sur SEO.....	26
Figure 5.1 Schéma d'articulation des éléments développés	31
Figure 5.2 Exemple de liaison de contrats par Entity Matching	34
Figure 5.3 Structure générale du RAG.....	35
Figure 5.4 Comparaison des méthodes de <i>retrieval</i>	37
Figure 5.5 Distribution des scores uniformes (orange) comparée aux prix facturés par le CCCQ (bleu)	38
Figure 5.6 Similarité après réentraînement	40
Figure 5.7 Évolution du marché – Exemple d’actualisation à la date T pour un contrat publié à la date t_{-1}	42
Figure 5.8 Schéma du modèle de tarification.....	46
Figure 5.9 Première page de l'outil (AOs en cours)	48
Figure 5.10 Deuxième page de l'outil (Analyse).....	49
Figure 5.11 Processus d'analyse (TO-BE).....	51
Figure 5.12 Processus d'analyse de scénarios (TO-BE).....	52
Figure 6.1 Schéma des données utilisées lors d'une expérimentation.....	55

LISTE DES SIGLES ET ABRÉVIATIONS

AO Appel d’offres

BID Offre

CCCQ Corps Canadien des Commissionnaires du Québec

LTR Learning to Rank

RAG Retrieval-Augmented Generation

SEAO Système électronique d’appel d’offres du gouvernement du Québec

LISTE DES ANNEXES

ANNEXE A	Processus de réponse général (AS-IS)	74
ANNEXE B	Processus de Réponse (AS-IS) partie 1 : préanalyse	75
ANNEXE C	Processus de Réponse (AS-IS) partie 2 : analyse.....	76
ANNEXE D	Processus de Réponse (AS-IS) partie 3 : Scénario Financier	77
ANNEXE E	Méthode de retrieval Sparse + Hierarchie	78

CHAPITRE 1 INTRODUCTION

Dans de nombreux secteurs d'activité, l'obtention de contrats constitue un enjeu central pour la croissance et la pérennité des organisations. Dans ce contexte, les appels d'offres constituent un mécanisme clé de mise en concurrence, permettant aux organisations publiques et privées de sélectionner les prestataires qui répondent le mieux à leurs besoins.

Lors d'un appel d'offres, l'organisme demandeur rend disponibles une description et un cahier des charges de la mission qu'il souhaite combler. Le mode d'adjudication est aussi énoncé. Deux modes sont prépondérants : l'adjudication au plus bas soumissionnaire (majoritaire) et l'adjudication hybride, qui repose sur une pondération des scores de qualité et de prix de l'offre. Les organismes répondants soumettent alors une proposition chiffrée, et dans certains cas, une proposition qualitative. L'adjudication est ensuite effectuée selon le mode désigné.

Pour l'organisation répondant aux offres, chaque soumission nécessite une étude chiffrée précise des charges humaines, matérielles et financières. Elle doit s'assurer que la réalisation de la mission lui est possible et lui procure une certaine rentabilité. Outre l'estimation des besoins et des charges de la mission, la réussite d'une proposition repose aussi sur la stratégie mise en place pour proposer une offre plus intéressante que celle de la concurrence. Cette stratégie doit intégrer de multiples aspects relatifs au marché dans lequel l'organisme évolue tout en maximisant les chances d'obtention du contrat et de rentabilité (Porter, 2008).

Les services de gardiennage, comme bien d'autres secteurs, sont régis par des appels d'offres. Notre partenaire, les Commissionnaires du Québec (officiellement le Corps Canadien des Commissionnaires – Division du Québec), occupe une position forte sur le marché québécois des services de sécurité, notamment des services de gardiennage sur lesquels nous travaillerons. En 2025, l'organisation génère un revenu de 747 M\$ avec plus de 22 millions d'heures de travail en sécurité (Commissionnaires du Québec, 2026). Les clients des Commissionnaires sont aussi bien des clients commerciaux que le gouvernement fédéral du Canada. La majorité des contrats sont obtenus au travers d'appels d'offres publics ; ainsi, la qualité du processus de réponse est vitale pour la pérennité de l'organisation.

Actuellement, les réponses sont construites de manière ad hoc, basées majoritairement sur les perceptions et les expériences des gestionnaires, alors qu'un nombre suffisant de données publiques ou internes est disponible et permettrait d'utiliser des méthodes de valorisation des données. La transformation numérique et l'essor des techniques de valorisation de données et d'intelligence artificielle constituent alors une opportunité sérieuse pour améliorer la prise de décision et ce processus important. L'utilisation des données historiques et actuelles relatives aux contrats ainsi qu'au marché permet d'optimiser le processus de sélection et de réponse en apportant des analyses chiffrées qui complètent les seules expériences et ressentis des experts sur lesquels reposent les stratégies actuelles. Toutefois, l'utilisation de ces approches comporte plusieurs défis. Les données pertinentes proviennent souvent de sources multiples, présentent des structures hétérogènes et sont en grande partie constituées de documents textuels, tels que les devis descriptifs des contrats. Cette complexité des données rend leur exploitation difficile à l'aide des méthodes d'analyse traditionnelles.

Dans ce contexte, **l'objectif principal de notre recherche est d'améliorer le processus de réponse aux appels d'offres en valorisant les données historiques.** Ainsi, nous proposons un outil qui fournit aux équipes de gestion des appels d'offres les indications nécessaires à l'établissement d'un prix stratégique, en tenant compte de la description de la mission ainsi que de l'environnement concurrentiel externe. Cet outil vise à développer une approche plus stratégique, quantitative et systématique assurant une hausse des chances d'adjudication du contrat ainsi qu'un rehaussement de la rentabilité. Le modèle intègre une phase d'évaluation des contrats, fondée sur le devis descriptif et l'historique interne de l'organisation.

Le présent mémoire vise à rendre compte de ce projet de recherche, il est structuré de la manière suivante. Le Chapitre 2 présente la revue de littérature, elle recense les principaux documents utiles en y apportant un regard critique. Ensuite, la méthodologie de recherche est abordée dans le Chapitre 3. À partir de la revue de littérature, on y apporte les objectifs spécifiques et la méthode employée. Dans le Chapitre 4, une analyse de l'existant présente le processus actuel de réponse aux appels d'offres. Le Chapitre 5 présente l'outil, son fonctionnement ainsi que ses optimisations. Le modèle est expérimenté et validé dans le Chapitre 6. Enfin, le Chapitre 7 apporte les conclusions du projet et propose des opportunités de recherche ultérieures.

CHAPITRE 2 REVUE DE LITTÉRATURE

Ce chapitre vise à présenter brièvement les principales contributions scientifiques portant sur la création de réponses à des appels d'offres valorisant les données historiques. Avant d'expliquer notre protocole de revue de littérature, nous présenterons les définitions des concepts clés qui seront utilisés par la suite. Le protocole de recherche et les articles retenus suivront. Finalement, nous exposerons un point de vue critique de la littérature, mettant en avant les faiblesses, manquements et limitations des contributions exposées, afin d'en identifier les opportunités de recherche.

2.1 Définition des concepts de base

Cette section expose les termes et concepts importants relatifs au sujet de ce mémoire. La compréhension claire de ces concepts permet de poser une base solide pour mieux comprendre le protocole présenté par la suite.

2.1.1 Appel d'offres

D'après la définition du Dictionnaire de la comptabilité et de la gestion financière, un appel d'offres se définit comme une « Procédure d'appel à la concurrence, par laquelle un acheteur éventuel de biens, de fournitures ou de services invite des fournisseurs à lui présenter des propositions précises en vue de l'attribution d'un marché » (*Dictionnaire de la comptabilité et de la gestion financière, version 1.2, 2006*). Ce processus met en concurrence directe les concurrents sur des bases communes, permettant une évaluation équitable des soumissions. Ces concurrents peuvent être quelconques dans le cas d'un appel d'offres public, ou sélectionnés dans le cas d'appels d'offres sur invitation. L'adjudication du contrat est ensuite conclue selon une méthode énoncée a priori. Dans la majorité des cas, cette méthode consiste en la sélection de l'offre la plus basse, parfois, une pondération de critères financiers et qualitatifs peut être utilisée.

Ce processus, majoritairement utilisé par des entités publiques ou d'envergure, assure la transparence de la sélection et une mise en concurrence efficace, favorisant une tarification plus juste.

2.1.2 Soumissionnaires

Un soumissionnaire est une organisation candidate à l'obtention d'un contrat qui dépose une offre dans le cadre d'un appel d'offres. Les soumissionnaires peuvent être de natures et tailles différentes et doivent s'assurer de leurs capacités à honorer ledit contrat. Conséquemment, ils peuvent choisir de se retirer s'ils estiment que le contrat leur est irréalisable ou non rentable. Chaque soumissionnaire doit, s'il souhaite soumissionner, analyser les besoins de la mission à accomplir et établir un devis financier. Ensuite, suivant la stratégie qu'il souhaite aborder pour assurer la réussite de son offre, il élabore son offre en choisissant notamment, la marge qu'il appliquera.

2.1.3 Stratégie de réponse

La stratégie de réponse est l'élément clé qui influence à la fois la réussite des offres soumises et leur rentabilité. Une première étape de cette stratégie consiste à décider de soumissionner ou non à un appel d'offres. Cette décision doit considérer bien sûr la capacité de réponse en termes de ressources, mais aussi l'environnement concurrentiel lors de l'appel d'offres. En effet, selon le nombre de concurrents, leur nature, l'historique du contrat ou encore le contexte interne de l'organisation, il peut être plus judicieux de laisser passer le contrat et d'éviter, par exemple, une mobilisation inutile de ressources. Ensuite, lorsque la décision de soumissionner est prise, la stratégie doit permettre d'établir le prix à soumettre, et notamment la marge à appliquer sur les coûts fixes. Ce prix doit permettre de gagner le contrat, tout en générant un profit intéressant. Plus particulièrement, lors d'une adjudication au plus bas soumissionnaire, on essaiera de remporter le contrat au prix le plus élevé possible, c.-à-d. proche du deuxième plus bas, la différence étant une perte pour le gagnant : le « winner's curse ». Cette stratégie doit alors se développer en tenant pleinement compte de l'environnement concurrentiel.

2.2 Protocole de recherche

En raison du caractère multidisciplinaire de notre domaine d'étude, nous utilisons la base de données scientifiques Scopus. Le choix de cette base de données réside dans sa grande diversité, offrant plus de 100 millions de contributions scientifiques.

Pour construire notre protocole de recherche, nous devons identifier les grands concepts liés à notre étude. Le seul domaine des appels d'offres pour des contrats de sécurité étant trop restreint pour dégager un nombre suffisant de contributions scientifiques, nous élargissons notre champ de

recherche à des secteurs plus vastes recourant à des procédures d'appel d'offres (notamment la construction, l'ingénierie ou l'approvisionnement public). On recherche alors les méthodes basées sur la donnée pour l'étude de contrats dans le cadre d'appels d'offres. Le plan de concept répertoriant les concepts et leurs synonymes est présenté dans le Tableau 2.1.

Tableau 2.1 Concepts clés de la revue de littérature

Appel d'offres	Stratégie de réponse	Par la donnée
Tender	Decision	Data-driven
Procurement	Evaluation	Historical data
Bidding	Strategy	Machine learning
Bids		Artificial intelligence
		Natural language process

En utilisant ces concepts, on construit une première requête : TITLE-ABS-KEY ((tender* OR procurement OR bidding OR bids) AND ("data-driven" OR "historical data" OR "machine learning" OR "artificial intelligence" OR "NLP" OR "natural language processing") AND (decision OR evaluat* OR strateg*)).

À la suite de l'analyse des premiers résultats, nous avons décidé d'ajouter des mots-clés et des exclusions, notamment sur les marchés d'enchères en temps réel pour l'énergie ou la publicité en ligne, afin d'affiner notre panel de résultats. Notre requête finale est alors : TITLE-ABS-KEY ((tender* OR procurement OR bidding OR bids) AND ("data-driven" OR "historical data" OR "machine learning" OR "artificial intelligence" OR "NLP" OR "natural language processing") AND (decision OR evaluat* OR strateg*) AND (contract) AND NOT (energy OR electric* OR advert* OR "ads"))

La requête, interrogée le 17 mars 2026, renvoie 187 résultats. Comme illustré à la Figure 2.1, on obtient un échantillon de 169 documents en appliquant des filtres sur les types de documents et la langue pour exclure les documents qui ne sont pas des articles ou des articles de conférence en anglais ou en français. Une première lecture des seuls titres des articles a alors permis d'éliminer 116 documents, majoritairement des contributions portant sur des thèmes connexes non pertinents

pour notre étude, tels que la détection de la corruption, les enchères sur des marchés financiers ou encore la gestion des appels d’offres du point de vue du demandeur. Enfin, la lecture des résumés, le cas échéant, des articles complets, a permis d’éliminer 28 publications supplémentaires. Finalement, 24 publications pertinentes, présentées dans le Tableau 2.2, ont été retenues. Ces dernières sont décrites dans la prochaine section.




Figure 2.1 Schéma de la revue de littérature

2.3 Résultats

Les articles identifiés traitent de sous-parties distinctes de notre sujet. Nous pouvons identifier quelques thèmes communs : les appels d’offres 4.0, la modélisation des décisions et des stratégies, l’extraction d’informations contractuelles et l’analyse des risques contractuels par intelligence artificielle.

2.3.1 Appels d’offres 4.0

L’émergence des nouvelles technologies 4.0 a transformé le processus des appels d’offres, donnant naissance à un processus digitalisé et réorganisé, avec de nouveaux besoins et de nouvelles opportunités. Simões et al. (2023) proposent une revue systématique de la littérature sur ce qu’ils nomment « Procurement 4.0 », en identifiant des technologies clés telles que l’intelligence artificielle et les systèmes ERP. Cette transformation se manifeste particulièrement dans l’optimisation des processus d’appels d’offres, où l’intégration de l’intelligence artificielle (IA) et de la robotisation logicielle permet désormais l’automatisation de tâches complexes telles que la génération de documents ou l’évaluation préliminaire des offres, notamment grâce au traitement du langage naturel (Cusumano, Rempling, et al., 2022). L’IA devient un levier décisionnel majeur, en effet, les algorithmes d’apprentissage automatique (Machine Learning) et de traitement du langage naturel (NLP) démontrent des capacités remarquables réduisant drastiquement le temps d’analyse tout en surpassant la précision d’évaluation humaine (Park et al., 2021). Ces techniques peuvent être utiles dans l’évaluation qualitative des risques associés aux contrats en utilisant des techniques de NLP pour, par exemple, constituer une évaluation fiable des risques. Malatesta et

Mancini (2026) posent un cadre et identifient les approches correspondantes. Enfin, ces techniques peuvent constituer des outils d'aide à la stratégie d'enchères, l'application de modèles prédictifs couplée à l'intelligence artificielle permet d'isoler les variables déterminantes lors du processus de réponse à un appel d'offres et d'offrir une visibilité sur les fourchettes de prix optimales pour remporter le marché (Molina-Miranda et al., 2023).

Auteurs	Année	Titre
Biruk et al.	2017	Modelling contractor's bidding decision
Charbel et al.	2025	Predicting the Level of Competition and Determining Optimal Bidding Strategies for Bundled Projects
Chisala	2017	Quantitative Bid or No-Bid Decision-Support Model for Contractors
Choi & Lee	2022	Contractor's Risk Analysis of EPC Contracts Using Ontological Semantic Model and Bi-LSTM
Cusumano, Saraiva, et al.	2022	Intelligent building contract tendering – potential and exploration
Cusumano, Rempling, et al.	2022	Natural language processing as work support in project tendering
Dawood	1994	Developing an integrated bidding management expert system for the precast concrete industry
Faraji et al.	2022	A Bid/Mark-Up Decision Support Model Based on Project Complexity in the Petroleum Industry
Kim et al.	2020	Application of Natural Language Processing (NLP) and Text-Mining of Big-Data to Engineering-Procurement-Construction (EPC) Bid and Contract Documents
Król et al.	2024	Application of ML Algorithms for Identification of Key Criteria Groups in Public Tendering
Lops et al.	2022	AI-based Decision Support Systems for the Management of E-procurement Procedures
Malatesta & Mancini	2026	AI-Enabled Contractual Knowledge and Risk Governance in EPC Projects
Mencia et al.	2013	Using Data Mining on Linked Open Data for Analyzing E-Procurement Information
Molina-Miranda et al.	2023	Application of explainable AI to analyze basic features of a tender
Moriyani et al.	2026	Beyond One-Size-Fits-All: A Novel Data-Driven Framework for Quantifying Bidding Competition Intensity
Padhy et al.	2021	Application of NLP to Automatically Identify Exculpatory Clauses in Construction Contracts
Park et al.	2021	A Digitalized Design Risk Analysis Tool with ML Algorithm for EPC Contractor's Technical Bid
Siciliani et al.	2023	AI-based decision support system for public procurement
Simões et al.	2023	Unlocking the Potential of Procurement 4.0: Digitalization, Industry 4.0, and Information Systems
Sturm et al.	2026	Augmenting Firm Diversification Behavior Prediction with Graph Embeddings
Tirmizi & Arif	2022	Conceptual Approach for the Use of AI for Contractual Risk Assessment in Infrastructure Projects
Vásquez & Kumral	2025	ANN and SVM for more accurate cost estimation in underground mining
Young-Hun & Gitae	2024	Analysis Bidding Price Analysis Using K-Means Cluster, ML, and Deep Learning
Zhang et al.	2026	Automated multi-label classification of risk clauses in construction contracts using GPT-driven data

Tableau 2.2 Articles retenus

2.3.2 Modélisation des décisions et stratégies de soumission des soumissionnaires

Cette thématique regroupe les contributions portant sur la modélisation des décisions de soumission, incluant la décision Bid/No-Bid, la détermination du prix et l'analyse de l'environnement concurrentiel.

2.3.2.1 Le processus de décision « Bid or No-Bid »

La décision de soumissionner ou non à un appel d'offres (« Bid/No-Bid ») constitue le premier arbitrage lors d'un processus de réponse. Il est important, puisqu'il s'agit de sélectionner les AOs intéressants tout en évitant le gaspillage de ressources sur d'autres moins intéressants ou vains. Historiquement, la majorité des entrepreneurs ont eu tendance à aborder cette décision de manière purement intuitive (Chisala, 2017). La littérature souligne cependant la nécessité de rationaliser ce processus.

Dès 1994, Dawood (1994) procède à une revue des besoins et des méthodes prometteuses. Il propose un système expert, fondé sur des règles intelligentes issues de contrats antérieurs, afin de s'affranchir des méthodes basées sur l'intuition. Plus récemment, les méthodes se sont développées, la décision est maintenant considérée comme un véritable problème multicritère. Dans leur publication, Biruk et al. (2017) proposent d'utiliser l'AHP (*Analytic Hierarchy Process*) pour la pondération multicritère, combinée à la programmation linéaire, afin de déterminer le prix de soumission et le degré de désirabilité du contrat. Dans la même logique, Chisala (2017) modélise cette évaluation de l'attractivité en pondérant 75 facteurs internes et externes afin de calculer un score adaptable en fonction de la tolérance au risque et des objectifs de l'entreprise. Pour aller plus loin, des analyses plus fines des caractéristiques intrinsèques du projet peuvent être considérées, Faraji et al. (2022) introduisent un indice de complexité du projet comme déterminant clé de la décision de soumission.

2.3.2.2 Modèle de soumission compétitive

La marge appliquée (ou mark-up) constitue la composante finale et décisive de la stratégie de soumission. Cette marge s'ajoute aux coûts directs et possibles provisions, son niveau, stratégique, doit prendre en compte les objectifs de l'entreprise ainsi que l'environnement concurrentiel (Vásquez & Kumral, 2025).

L'intégration de variables qualitatives dans le calcul de la marge est un sujet récent. Les modèles anciens comme celui de Gates ou de Friedman (1956; 1967), strictement mathématiques, sont améliorés par des systèmes experts fondés sur l'expérience managériale (règles heuristiques) pour pondérer des facteurs tels que la réputation du client ou le contexte économique (Dawood, 1994). Les approches récentes se distinguent selon qu'elles se concentrent sur les attributs intrinsèques du contrat ou sur les dynamiques du marché dans lequel s'inscrit la soumission. À l'échelle du contrat individuel, plusieurs travaux proposent de calibrer la marge en fonction des caractéristiques propres au projet. Biruk et al. (2017) proposent d'ajuster la marge par interpolation en fonction d'un score d'attractivité global, ce qui la fait osciller entre deux bornes justifiables. Faraji et al. (2022) montrent que les marges, financières ou temporelles, peuvent être corrélées à un indice de complexité du projet à l'aide de modèles de régression non linéaires, permettant d'identifier des seuils de marges viables. Dans le domaine minier, García Vásquez et Kumral (2025) comparent les réseaux de neurones artificiels (ANN) et les machines à vecteurs de support (SVM) pour l'estimation des coûts de projets souterrains du point de vue du contracteur. Au-delà de la précision, la rapidité de traitement est 80 fois supérieure à celle de l'estimation manuelle, ce qui constitue un avantage considérable lors de la phase de préparation des soumissions. À l'échelle du marché, d'autres travaux s'intéressent à la structure concurrentielle et aux comportements agrégés des soumissionnaires afin de guider la détermination des prix. Young-Hun et Gitae (2024) appliquent le clustering K-Means, suivi de modèles d'apprentissage automatique (arbre de décision, forêt aléatoire, SVM, KNN) et d'apprentissage profond (perceptron multicouche), à l'analyse des prix de soumission dans les marchés publics, révélant que les prix attendus se situent dans une fourchette de 88 %, signe de comportements de soumission stables au sein de chaque groupe de projets. Charbel et al. (2025) intègrent des algorithmes d'apprentissage automatique (Random Forest, ANN, KNN, Decision Tree, SVM, GBM, LightGBM, CatBoost) aux modèles probabilistes de Friedman et de Gates pour prédire le niveau de concurrence et déterminer les stratégies de soumission optimales dans le contexte de projets groupés. En sélectionnant les variables à l'aide de l'algorithme Boruta et en recourant à des simulations de Monte Carlo, ce cadre identifie les variables clés influant sur la concurrence (durée du projet, montant estimé, mois de publication) et permet aux contracteurs de quantifier les probabilités de victoire et les attentes de profit.

2.3.2.3 Facteurs de compétitivité

Au-delà des attributs contractuels, la dynamique concurrentielle est également liée à la structuration même du marché. L'évaluation de l'environnement concurrentiel constitue un enjeu non négligeable dans l'élaboration de la stratégie.

À ce titre, Charbel et al. (2025) mettent en évidence que le regroupement de projets (*bundled projects*) restreint la concurrence aux grandes entreprises dotées de fortes capacités en termes de ressources. De plus, les auteurs exposent comment la saturation du marché contraint les entreprises à adopter des stratégies de prix agressives, réduisant ainsi significativement les marges. Moriyani et al. (2026) proposent une approche s'appuyant sur les réseaux de neurones sur graphes (GNN) pour modéliser les relations entre les compétiteurs. L'intensité de la concurrence est alors quantifiée et montrée comme étant intrinsèquement liée aux attributs spécifiques du contrat, offrant des métriques de compétition fondées sur les données qui dépassent le simple décompte du nombre de soumissionnaires. Toujours dans le domaine de l'exploitation des modèles de graphes, Sturm et al. (2026) utilisent les *graph embeddings* via l'algorithme Node2Vec pour prédire le comportement de diversification des entreprises sur les marchés publics. Cette approche fournit alors des indications sur les types de contrats préférés ainsi que sur les secteurs forts des différents acteurs du marché. Dans une approche plus globale du marché, Siciliani et al. (2023) et Lops et al. (2022) développent des systèmes de détection d'anomalies en identifiant des indicateurs de risques critiques tels qu'une structure de marché hyperconcentrée, l'absence d'acteurs historiques ou encore la présence de soumissionnaires superflus déposant des offres artificielles. Enfin, Król et al. (2024) abordent la standardisation des critères d'évaluation des marchés publics. En appliquant le traitement du langage naturel et un algorithme de clustering, ils développent une analyse et une comparaison des critères d'évaluation entre différentes procédures d'approvisionnement, fournissant ainsi aux soumissionnaires une compréhension plus claire des critères d'évaluation.

2.3.3 NLP pour l'extraction d'information contractuelle

La collecte et l'extraction de données sont cruciales pour alimenter les méthodes décrites précédemment. Des données structurées sur les marchés peuvent être disponibles directement sur des plateformes de données ouvertes (Moriyani et al. (2026) ; Faraji et al. (2022)) ou via des techniques d'exploration web avec des « *crawler* » (Król et al. (2024) ; Lops et al. (2022)). Cependant, une grande partie des informations relatives aux contrats eux-mêmes n'est disponible

que sous forme non structurée dans les documents au format PDF. Une phase de prétraitement est indispensable, Choi & Lee (2022) ainsi que Park et al. (2021) insistent sur la structure de ces fichiers, nécessitant l'élimination du bruit et l'usage de parseurs couplés avec la reconnaissance optique de caractères (OCR). Kim et al. (2020) utilisent des lexiques sémantiques domaine-spécifique pour extraire des clauses et les classifier. Padhy et al. (2021) s'appuient eux sur la tokenisation et des outils basés sur des règles (*PhraseMatcher*) pour extraire l'information clé. L'extraction avancée s'oriente vers des approches sémantiques et de traitement du langage naturel (NLP). Mencia et al. (2013) développent des algorithmes récurrents pour convertir des données sémantiques en formats relationnels. Des modèles de vectorisation comme Sentence-BERT sont utilisés par Król et al. (2024) puis Zhang et al. (2026) explorent le potentiel des grands modèles de langage (LLM). Cette automatisation est nécessaire à la constitution des bases de données standardisées requises pour le développement de modèles performants. Des données historiques standardisées de qualité sont un défi important mais obligatoire pour l'utilisation optimale des données (Cusumano, Saraiva, et al., 2022).

2.3.4 Analyse de risques contractuels par intelligence artificielle

L'identification et l'évaluation automatiques des risques contractuels constituent un axe de recherche majeur visant à améliorer la qualité des décisions de soumission.

Kim et al. (2020) construisent les premières tentatives de classification de clauses extraites en utilisant des règles sémantiques. Ensuite, Park et al. (2021) développent un outil d'analyse des risques de conception pour l'évaluation des spécifications techniques lors de la soumission en contexte EPC (*Engineering, Procurement & Construction*). Leur système comprend deux modules basés sur l'apprentissage automatique : l'extraction des risques techniques (TRE) et l'extraction des paramètres de conception (DPE). Le module TRE obtient un avantage de précision de moitié supérieur à celui de l'extraction manuelle, tandis que le module DPE réduit considérablement le temps d'analyse par rapport à la revue manuelle par un ingénieur, avec une classification des risques en cinq niveaux de sévérité. Toujours dans le cadre des contrats EPC, Choi & Lee (2022) combinent un modèle sémantique ontologique avec des réseaux de mémoire bidirectionnels à long et à court terme (Bi-LSTM) pour l'analyse des risques. Plus récemment, Zhang et al. (2026) ont utilisé les modèles de langage génératif GPT-2 et GPT-4 pour l'augmentation de données dans la classification multi-labels des clauses de risque dans les contrats de construction.

Plus globalement, Tirmizi et Arif (2022) proposent un cadre conceptuel s'appuyant sur les réseaux de neurones artificiels (ANN) pour l'évaluation des risques contractuels dans les projets d'infrastructure pétrolière. Leur approche repose sur trois bases de données (risques, impacts, stratégies d'atténuation) et identifie les risques contractuels. Le système fournit un classement de l'impact des risques et des solutions correctives, répondant aux problèmes organisationnels liés au travail en silos et au manque d'expertise en matière de rédaction contractuelle.

2.4 Analyse critique

L'analyse de la littérature révèle une évolution significative des méthodes utilisées pour soutenir le processus d'appels d'offres. Les premiers travaux, datés des années 1990, reposent sur des systèmes experts et des méthodes multicritères classiques. Ensuite, la période 2010–2020 voit l'émergence des méthodes de fouille de données et des modèles quantitatifs de prise de décision. Enfin, à partir de 2020, une accélération marquée s'observe avec l'adoption du NLP, du *deep learning* et des modèles de langage, ainsi que des architectures de graphes.

On distingue trois grandes catégories d'approches. Les méthodes d'apprentissage supervisé classiques (forêt aléatoire, SVM et réseaux de neurones) sont largement employées pour la prédiction des prix, la classification et l'estimation des coûts, avec des performances souvent remarquables. Ensuite, les techniques de NLP et de traitement de texte gagnent en sophistication, passant d'approches basées sur des règles sémantiques à des modèles de *transformers* comme GPT. Enfin, les approches fondées sur les graphes émergent comme une catégorie novatrice, permettant de modéliser les relations structurelles entre les acteurs du marché et les contrats.

Malgré les avancées significatives de la littérature, plusieurs limites et lacunes méritent d'être soulignées. Tout d'abord, la fragmentation des approches. La plupart des contributions se concentrent sur un seul aspect du processus d'appels d'offres de manière isolée : soit la décision Bid/No-Bid, soit l'estimation des coûts, soit l'analyse documentaire. Très peu de travaux proposent un cadre intégré couvrant l'ensemble du cycle de réponse, de la détection de l'opportunité jusqu'à la formulation du prix. Seuls Lops et al. (2022) et Siciliani et al. (2023) adoptent une approche systémique, mais leurs travaux restent centrés sur le contexte de l'approvisionnement public italien. Cette fragmentation se double d'un problème de généralisabilité : de nombreuses contributions sont ancrées dans un secteur spécifique (construction, EPC, mines) ou dans un contexte géographique

particulier (Corée, Pologne, Équateur, Italie), ce qui rend incertaine la transférabilité des modèles. Le secteur des services, et a fortiori celui de la sécurité, demeure largement sous-représenté, alors qu'il présente des spécificités notables, telles que la grande prédominance des coûts de main-d'œuvre, la récurrence des contrats et une proportion de coûts variables très faible (notamment par rapport au secteur de la construction).

Ensuite, le traitement des données. D'une part, l'intégration de données multimodales reste un défi; les méthodes de NLP excellent dans le traitement de documents textuels, tandis que les modèles prédictifs exploitent des données structurées. Cependant, le processus réel de réponse implique la fusion de ces deux types de sources, auxquels s'ajoutent les informations concurrentielles et les connaissances tacites des équipes. D'autre part, l'ensemble des travaux recensés porte sur des corpus anglophones, alors que notre contexte opérationnel repose sur des contrats rédigés en français, ce qui pose des défis supplémentaires en termes de ressources linguistiques et de modèles pré-entraînés disponibles. Par ailleurs, la dimension temporelle et dynamique du marché est souvent négligée; les modèles existants supposent généralement un environnement statique, alors que les conditions de marché, la stratégie des concurrents et les besoins des clients évoluent dans le temps. Seuls Sturm et al. (2026) proposent une validation temporelle par fenêtres croissantes, mais cette approche demeure limitée.

Enfin, les considérations pratiques liées au déploiement sont rarement abordées. La plupart des contributions restent au stade de prototype ou de preuve de concept, sans évaluation de leur intégration aux processus opérationnels existants. Cusumano et al. (2022) constituent une exception avec leur évaluation auprès d'utilisateurs finaux, qui révèle des préoccupations quant à la fiabilité de l'outil et à la qualité des données.

Un récapitulatif de cette analyse critique est présenté dans le Tableau 2.3.

Tableau 2.3 Récapitulatif de l'analyse critique

Auteurs	Caractéristiques des méthodes					
	Décision de soumission	Décision de prix/marge	Données techniques	Données du marché	Extraction de données	Variables temporelles
(Biruk et al., 2017)	✓	✓	✓			
(Charbel et al., 2025)		✓	✓	✓		
(Chisala, 2017)	✓		✓	✓		
(Choi & Lee, 2022)			✓		✓	
(Cusumano, Saraiva, et al., 2022)					✓	
(Cusumano, Rempling, et al., 2022)					✓	
(Dawood, 1994)	✓	✓	✓	✓		
(Faraji et al., 2022)	✓	✓	✓			
(Vásquez & Kumral, 2025)		✓	✓			
(Kim et al., 2020)			✓		✓	
(Król et al., 2024)					✓	
(Lops et al., 2022)			✓		✓	
(Malatesta & Mancini, 2026)					✓	
(Mencia et al., 2013)				✓	✓	
(Molina-Miranda et al., 2023)		✓		✓		
(Moriyani et al., 2026)	✓			✓		✓
(Padhy et al., 2021)			✓		✓	
(Park et al., 2021)	✓		✓		✓	
(Siciliani et al., 2023)				✓	✓	
(Simões et al., 2023)						
(Sturm et al., 2026)				✓		✓
(Tirmizi & Arif, 2022)			✓			
(Young-Hun & Gitae, 2024)		✓	✓	✓		
(Zhang et al., 2026)			✓		✓	

2.5 Conclusion

Cette revue de littérature a permis de dresser un portrait complet des contributions scientifiques portant sur l'application de l'intelligence artificielle et des méthodes fondées sur les données au processus d'appels d'offres. L'analyse de 24 articles publiés entre 1994 et 2026 révèle trois axes de recherche principaux : la digitalisation des processus d'approvisionnement et le développement de systèmes intégrés d'aide à la décision ; la modélisation formelle des décisions de soumission et

des stratégies de prix ; et le traitement automatique des données non structurées issues des documents contractuels.

Néanmoins, notre analyse critique révèle des lacunes significatives : fragmentation des approches, manque d'intégration entre les différentes étapes du processus, généralisabilité limitée, absence du secteur des services, et rareté des validations empiriques en contexte opérationnel. Ces constats motivent et orientent notre recherche, qui vise à développer un cadre intégré d'aide à la décision exploitant conjointement l'extraction automatisée d'information, l'analyse de données historiques et la formulation de stratégies de prix. Le tout validé dans le contexte réel des contrats de sécurité des Commissionnaires du Québec. Le prochain chapitre décrit la méthode utilisée lors de ce projet de recherche.

CHAPITRE 3 Méthodologie de recherche

3.1 Introduction

Le présent chapitre décrit la démarche de recherche utilisée. Nous exposons d'abord nos objectifs spécifiques, puis présentons l'approche méthodologique retenue pour les atteindre.

3.2 Objectifs de recherche

L'objectif général de notre recherche est *d'améliorer le processus de réponse aux appels d'offres en cherchant à valoriser les données historiques* en intégrant notamment des méthodes d'intelligence artificielle et de valorisation des données. Pour y arriver, plusieurs objectifs spécifiques ont été définis :

- Caractériser les variables et indicateurs décisionnels qui structurent les décisions de soumission;
- Déterminer quels modèles et approches issus de la littérature sont transposables au contexte spécifique du partenaire; et
- Adapter les approches retenues et valider leur viabilité en contexte réel, en l'appliquant à des données historiques de notre partenaire.

3.3 Méthodologie de recherche

Ce projet de recherche vise à développer des outils pour faciliter et améliorer la gestion des réponses aux appels d'offres dans le cadre de contrats de services de gardiennage. L'outil ainsi que les modèles associés accompagneront les gestionnaires à différents moments du processus de réponse, de la publication ou prépublication d'un appel d'offres à l'établissement du scénario financier à privilégier lors de la soumission. Cet outil devra permettre la prise en compte de multiples indicateurs décisionnels, tant sur le contrat que sur l'environnement concurrentiel. Pour cela, nous devons développer les capacités de traitement et d'intégration des données brutes et multimodales mais aussi des modèles afin d'extraire, au final, des informations viables et pertinentes.

La méthodologie retenue pour conduire cette recherche est l'approche Design Research Methodology (DRM), développée par Blessing et Chakrabarti (2009). On justifie ce choix par la nature de la contribution visée : un outil, dont l'utilité doit être démontrée tant sur le plan

scientifique que sur le plan opérationnel. Cette méthode nous permet d'évaluer les bénéfices de notre contribution sans nécessiter une mise en œuvre complète. La DRM structure la recherche en quatre phases séquentielles et itératives, illustrées dans la Figure 3.1. Premièrement, la revue de littérature permet de définir clairement les objectifs de recherche et de délimiter le périmètre fonctionnel de l'outil. Ensuite, l'analyse descriptive du cas d'étude vise à comprendre l'état actuel du phénomène étudié et les données disponibles. Puis, l'étude prescriptive constitue le cœur du travail de conception et de développement de l'outil et de ses éléments. Enfin, une seconde analyse descriptive permet d'évaluer l'outil développé en l'utilisant dans différentes situations de notre cas d'étude.




Figure 3.1 Structure de la méthodologie DRM, adaptée de Blessing et Chakrabarti

Dans les précédents chapitres, nous avons réalisé la phase de clarification du projet de recherche à l'aide d'une revue systématique, permettant l'identification exhaustive des pratiques actuelles relatives au cadre de notre sujet. L'analyse critique a permis d'exposer les limites de ces pratiques et de percevoir les manquements qui constituent des opportunités de recherche.

Le CHAPITRE 4 présente l'analyse du cas d'étude. Le processus est modélisé selon le formalisme BPMN2.0, adapté pour la modélisation des interactions de données et des prises de décision. Cette modélisation permet l'identification des faiblesses du processus et de l'intégration des potentiels apports de notre recherche. Les données externes utilisées proviennent de la base de données ouverte et du site web du système électronique d'appels d'offres du gouvernement du Québec (SEAO), un filtrage a été effectué afin de ne garder que les appels d'offres relatifs aux services de

gardienage et dans leur dernière actualisation. Les données internes utilisées sont directement issues des documents contractuels mis en ligne par les clients lors de la publication des appels d'offres et téléchargés par le partenaire, les données extraites constituent les caractéristiques techniques des contrats.

Les outils développés sont exposés dans le CHAPITRE 5, où le caractère itératif de la méthodologie DRM nous a permis d'évaluer en continu les éléments nécessaires à notre outil final. L'utilisation de méthodes de résolution d'entités nous permet de retrouver les contrats passés malgré les variations dans les champs d'identification. Le développement d'outil de génération augmentée de récupération (RAG) permet la compréhension des subtilités d'un contrat pour l'extraction et le calcul systématique de variables d'un contrat directement depuis le document contractuel. Pour récupérer des contrats similaires sur le plan technique, un réseau de neurones simple a été initialisé puis réentraîné à partir de classements humains afin de saisir les caractéristiques réellement importantes selon l'expérience des gestionnaires. Ensuite, un modèle de tarification *Learning to Rank* permet de classer des marges potentielles selon leur optimalité et chance de gain de l'appel d'offres, ce modèle basé sur XGBoost est cohérent considérant la taille relativement faible de notre base de données. Enfin, une interface graphique est développée via la librairie python *streamlit*, permettant ainsi un déploiement aisé dans l'environnement du partenaire et une utilisation accessible pour les gestionnaires.

Nous abordons l'application et les résultats de notre outil dans le CHAPITRE 6. Pour évaluer notre outil ainsi que les différents éléments développés au cours de notre recherche, nous pourrions nous appuyer sur les données historiques de notre partenaire pour les 5 dernières années, ainsi que sur des données ouvertes publiées par le gouvernement. Nous actualisons nos données tout au long du projet afin de constituer un panel de données le plus proche possible de l'actualité. L'algorithme de résolution d'entité est évalué sur la proportion de vrais positifs retournés pour les contrats de l'année 2025. Nous appliquons ensuite notre outil à des situations, c.-à-d. des publications d'appels d'offres plus ou moins récentes, afin de comparer la validité des modèles mis en place, mais aussi les performances par rapport au comportement réel de notre partenaire. Les performances sont étudiées en prenant en compte le rang, c.-à-d. la place à laquelle le soumissionnaire finit, et le profit dégagé. Nous utilisons 57 contrats publiés au cours de l'année 2023 et de l'année 2024 pour tester le comportement général de notre modèle. Enfin, nous étudions 20 contrats publiés entre 2023 et aujourd'hui, des contrats auxquels notre partenaire a participé, afin de valider et de comparer les

performances entre notre modèle et l'historique du partenaire. Les données utilisées lors de ces expérimentations sont les données antérieures d'au moins un certain temps afin de prendre en compte les temps de publication des résultats d'un appel d'offres.

3.4 Conclusion

La méthodologie appliquée au cours de notre projet de recherche sera la méthodologie DRM. Cette méthode permet une validation progressive de nos outils sans en exiger le déploiement opérationnel complet. Nous proposerons un cadre d'outils intégrant de multiples indicateurs décisionnels. Ce cadre est un environnement complet allant de la collecte et transformation des données brutes et multimodales jusqu'au calcul et à la visualisation des indicateurs pertinents pour le gestionnaire lors du processus de réponse aux appels d'offres. Le prochain chapitre présente le cas d'étude et ses spécificités.

CHAPITRE 4 Analyse de l'existant

Dans ce chapitre, nous présentons notre partenaire, le cas d'étude, le processus existant, ainsi que les données sur lesquelles nous allons nous appuyer pour développer notre outil. Nous commencerons par une présentation générale de notre partenaire, puis du cas d'étude, afin de saisir les contraintes et le contexte de notre projet. Ensuite, nous exposerons le processus de réponse aux appels d'offres en vigueur afin d'identifier les améliorations possibles. Enfin, nous exposerons les données utilisables et leurs spécificités.

4.1 Présentation du partenaire

Cette section vise à présenter le partenaire associé à ce projet, son domaine d'activité ainsi que son organisation, afin de préciser le contexte de notre recherche.

Notre partenaire, les Commissionnaires du Québec (officiellement le Corps canadien des Commissionnaires – Division du Québec), est une organisation de sécurité à but non lucratif centenaire, dont la mission sociale est de soutenir les vétérans. C'est un acteur de premier plan dans les services de sécurité au Québec, et notamment dans les services de gardiennage et de patrouille pour des entités publiques comme privées avec plus de 22 millions d'heures travaillées et 747 M\$ de revenus en 2025 (*À propos de Commissionnaires*, 2026).

Le bureau des Commissionnaires est organisé en plusieurs divisions. Les différentes entités de ces divisions peuvent intervenir à divers niveaux du processus.

C'est le centre d'excellence (CDE), une composante de la division financière, qui a pour mission de piloter le processus de renouvellement ou d'acquisition de contrats issus d'appels d'offres. Constituée de plusieurs pôles, cette sous-division gère le processus de la prospection des opportunités à la construction des formulaires de réponse contenant l'offre financière définie ainsi que les différents requis (documents juridiques, références, preuves de capacités techniques, etc.).

Pour les deux décisions cruciales du processus, à savoir la décision de soumissionner et le choix de la marge à appliquer, un panel multi-divisions est consulté. Ce panel est composé de directeurs des entités d'opération, de finances, de ressources humaines et d'autres divisions ou sous-divisions si nécessaire.

4.2 Cas d'étude

Nous présentons dans cette section le cas d'étude spécifique de notre recherche, le cas du processus de réponse aux appels d'offres, un processus crucial pour la pérennité de notre partenaire.

4.2.1 Appels d'offres

Nous nous intéressons au processus d'appel d'offres. Celui-ci est particulièrement important pour les Commissionnaires puisqu'une écrasante majorité des contrats de gardiennage au Québec sont octroyés via ce processus. Les différents clients, qu'ils soient publics (villes, ministères, centres de services scolaire, etc.) ou privés (commerces, bureaux, musées, etc.) publient sur la plateforme gouvernementale *Système électronique d'appel d'offres du gouvernement du Québec* (SEAO) les documents contractuels (régie, contrat, devis, formulaire de soumission) liés au contrat qu'ils souhaitent pourvoir. Selon le type d'appel d'offres, ouvert ou sur invitation, différents soumissionnaires sont libres de proposer une offre s'ils remplissent les critères. Une période d'environ un mois leur permet d'élaborer celle-ci. Durant celle-ci, les soumissionnaires peuvent poser des questions concernant le contrat. Si des clarifications ou des modifications y ont lieu, des addenda sont publiés. Des critères tels que la détention de certaines certifications, la réalisation de missions similaires auprès d'autres clients ou encore la preuve de capacités techniques pour la réalisation de la mission peuvent être requis pour la participation. Ensuite, après le dépôt des offres par les soumissionnaires, les résultats d'ouverture sont publiés. Enfin, le contrat est adjudgé selon des modalités précisées en amont, dans de rares cas, avec une pondération de critères financiers et qualitatifs, mais plus généralement à l'offre financière la plus basse. Sadoune et al. (2023) utilisent d'ailleurs ces mêmes données de SEAO pour entraîner des modèles de simulation d'enchères au plus bas prix. Ce processus est décrit dans la Figure 4.1.




Figure 4.1 Processus de publication d'un AO sur SEO

4.2.2 Contrats

Les contrats que nous étudions sont des contrats de gardiennage et de patrouille. Dans ceux-ci, les soumissionnaires doivent fournir des agents pour assurer la sécurité d'un lieu (commerces, bureaux, centres de services scolaires, établissements de santé, etc.). Parfois les lieux peuvent être multiples et les demandes sur appel, c'est le cas lors des patrouilles où des agents doivent se déplacer sur les lieux d'un appel ou d'une alarme.

Les spécificités techniques à considérer pour un contrat sont définies dans le devis technique présenté par le client. Elles comprennent :

- Les horaires et le volume d'heures travaillées des agents ;
- Les primes à accorder aux agents ;
- Les besoins matériels : uniformes, équipements et véhicules ;
- Les heures de formations obligatoires ; et
- Les possibles pénalités.

Le coût de la main-d'œuvre, c'est-à-dire le taux horaire des agents, représente la part la plus importante du prix du contrat. C'est souvent ce montant que le client demande d'indiquer dans le bordereau de prix lors de la réponse à un appel d'offres. Au Québec, le *Décret sur les agents de sécurité*, D-2, r. 1 (Loi sur les décrets de convention collective, 2026) régit le taux horaire et les primes horaires minimum des agents, ainsi, un prix plancher légal peut être calculé pour chaque contrat. C'est ce prix que l'on utilise pour définir le ratio de marge (Eq 4.1). La répartition des coûts dans le taux horaire total par agent est exposée dans la Figure 4.2.

$$\text{Ratio de marge} = \frac{\text{Prix total soumis}}{\text{Prix minimum régi par le décret}} \quad (4.1)$$




Figure 4.2 Répartition des coûts dans le taux horaire d'un agent (échelle indicative)

En général, les contrats présentent une grande similitude, notamment en ce qui concerne la mission confiée et la méthode utilisée pour déterminer le prix à proposer.

4.3 Processus en place aux Commissionnaires

Les processus actuellement en place pour la réponse aux appels d'offres des Commissionnaires sont présentés dans les annexes A, B, C, et D selon le formalisme BPMN 2.0. (« Business Process Model and Notation (BPMN), Specification Version 2.0 », 2011), le formalisme de référence le plus adapté dans notre cas, permettant la prise en compte de la donnée et de la prise de décisions (Mosser et al., 2022).

L'Annexe A décrit le processus global constitué des grandes étapes depuis l'identification d'un potentiel contrat jusqu'à la conclusion du processus de réponse. On distinguera quatre grandes étapes. La préanalyse, qui conduit à la première décision majeure du processus : la décision de soumissionner ou non à l'appel d'offres considéré. Si la décision de soumissionner est prise, les étapes suivantes sont liées : la préparation de l'analyse, l'étude des scénarios financiers et la finalisation du dossier.

La préanalyse, décrite dans l'Annexe B doit permettre aux décideurs de choisir si l'appel d'offres considéré est viable et possible selon les ressources disponibles. Le centre d'excellence (CDE) réalise cette préanalyse, on y documente les premières informations caractéristiques du contrat (nombre d'heures, durée, client, etc.) ainsi que les contraintes et éléments qui pourraient constituer des impacts financiers. Lors de ce processus, le CDE peut échanger avec le client pour résoudre de potentielles questions, celles-ci sont généralement clarifiées via des addenda publiés par le client sur la plateforme en ligne SEAO. La synthèse des informations documentées lors de cette préanalyse est ensuite présentée à un comité exécutif constitué d'un panel de directeurs des entités d'opération, de finances, de ressources humaines, et d'autres divisions ou sous-divisions si nécessaire. La décision de poursuivre est alors prise.

Si la décision de poursuivre l'appel d'offres est prise, on entre alors dans le processus de préparation de la réponse à l'appel d'offres. Lors de l'analyse (Annexe C), on référence puis on calcule tous les éléments et frais relatifs au contrat (heures, primes, ressources, assurances, formations, etc.). À ce moment, nous avons le coût brut du contrat ; il reste alors à déterminer la marge appliquée pour obtenir le prix à soumettre au client. C'est ce qui est fait lors de l'étape d'étude des scénarios financiers (Annexe D). On cherche alors la marge à appliquer qui satisfait les attentes du marché et assure le profit du contrat. Pour cela, le directeur du CDE peut s'appuyer sur quelques données, ainsi que sur son expérience du marché. Lorsque le contrat est conséquent, on consulte le comité exécutif pour établir les directives particulières à appliquer. Une fois la marge choisie, notre offre financière est finalisée, on peut alors remplir le bordereau de prix à soumettre au client. Une dernière étape de finalisation du dossier a lieu pendant laquelle on construit, au besoin, l'offre qualitative constituée des documents répondant aux exigences du client. Le processus de réponse s'achève par la soumission de l'offre au client.

Le processus décrit ci-dessus comporte quelques imperfections :

- La faible intégration de décisions fondées sur des indicateurs précis et systématiques, prenant en compte le contexte, qu'il s'agisse du contrat ou du marché. Majoritairement, ce sont l'intuition et l'expérience des gestionnaires qui priment lors des décisions;
- L'accès aux données disponibles est difficile. Elles sont stockées dans un environnement infonuagique de manière désorganisée, ce qui complique leur recherche, même lorsqu'elles existent. Seules les données des contrats étudiés en profondeur par les Commissionnaires sont conservées. Le gestionnaire doit donc se rappeler si une donnée peut exister dans la base de données, puis la rechercher manuellement et inefficacement, ce qui décourage son utilisation;
- L'absence de suivi systématique et non biaisé des résultats freine la mise en œuvre de stratégies de mitigation. Les retours d'expérience sont mal maîtrisés et leur prise en compte difficile car la transposition des résultats à d'autres contrats semble floue; et
- L'absence de processus défini et automatisé pour la récupération de nouvelles opportunités. La prospection se fait de manière manuelle et sans anticipation, ce qui pourrait permettre une meilleure phase de préparation ou de lobbying, renforçant la position du partenaire pour remporter le contrat.

4.4 Données disponibles

Pour le développement de nos outils, nous avons d'abord mené une analyse approfondie des différentes bases de données sur lesquelles nous pourrions nous appuyer.

4.4.1 Données externes

Une première base de données importante constitue la plateforme du Système électronique d'appel d'offres du gouvernement du Québec (SEAO). Cette plateforme héberge la grande majorité des processus d'appel d'offres auxquels les Commissionnaires participent. La plateforme publie de manière hebdomadaire et publique via Open Canada les résultats des appels d'offres passés ou en cours.

Bien que les données publiées sous forme semi-structurée (json) puissent déjà être d'une utilité conséquente, nous nous appuierons plutôt sur ces publications pour retrouver les liens URL directs des pages web relatives à chacun des contrats (inaccessibles directement depuis le site). Ces pages recensent bien plus d'informations que l'on peut extraire à l'aide de techniques de *Web Scraping*.

Cette technique pourra aussi être utilisée de la même manière pour aller chercher de manière automatique, les nouvelles publications ou anticiper de potentielles opportunités. Le schéma de ce processus de collecte est décrit dans la Figure 4.3.




Figure 4.3 a) Schéma de la récupération des données SEO ; b) Exemple d'une page Web d'AO sur SEO

La base de données Open Canada publie l'ensemble des appels d'offres du Québec, on utilise alors des filtres sur les titres ainsi que sur les codes UNSPSC (*Classification universelle normalisée des produits et des services des Nations Unies (UNSPSC)*, 2026). Comme chaque nouvelle publication dans la base de données peut ne signifier qu'une mise à jour de l'état d'un appel d'offres, on ne conserve finalement que l'état le plus récent.

Les données récupérées à partir des pages Web sur SEO comprennent : Résumé de l'avis ; Résultats d'ouverture ; Conclusion du contrat ; Dépenses supplémentaires ; Information finale ; et Historique des correctifs (sous-menus de la page). Les principales informations utiles extraites sont non exhaustivement répertoriées dans le Tableau 4.1.

On constitue ainsi une base de données de 1960 publications publiées entre le 2015-01-01 et le 2026-03-27. Parmi celles-ci, 94 % (1836) des conclusions de contrats sont disponibles, et pour les AOs ouverts ou sur invitation, qui représentent 49 % (957), 95 % (908) des résultats sont disponibles.

Tableau 4.1 Données extraites de la plateforme SEAO

Menu	Champ	Description
Informations générales	Numéro	Numéro client unique du présent contrat
	Numéro de référence SEAO	Numéro dans SEAO, peut être le même pour certains renouvellements de contrat
	Type	Le type de l'AO : ouvert, sur invitation, gré-à-gré, etc.
	Statut	Le statut : en cours, résultats d'ouverture, terminé.
	Titre	Le titre du contrat
	Lots	Les lots s'il y a lieu
	Client	Le nom du client et ses informations d'adresse et de contact.
Résumé	Durée prévue sans les options ¹	La durée de base du contrat en mois.
	Durée prévue des options	La durée des options en mois.
	Date publication	La date de publication de l'AO.
	Date limite de réception	La date de fin de l'AO
	Région de livraison	La région dans laquelle le contrat a lieu.
Résultats d'ouverture	Soumissionnaire	Le nom du soumissionnaire.
	Montant soumis	Le montant soumis par le soumissionnaire.
Conclusion du contrat	Soumissionnaire retenu	Si le soumissionnaire a été retenu (il peut y en avoir plusieurs).
	Montant du contrat	Le montant du contrat adjugé (souvent le même que le montant soumis par définition).
Dépenses supplémentaires	Dépense	Montant et raison de l'ajout.
Information finale	Date de fin du contrat	La date de fin du contrat.
	Nombre d'options exercées	Le nombre d'options qui ont été exercées.
	Montant total payé	Le montant total versé au soumissionnaire (peut différer du montant adjugé lors de contrat sur appels).
Historique des correctifs	Correctif	Date de correction et champs corrigés.

4.4.2 Données internes

Lorsque les Commissionnaires débutent un processus de réponse à un appel d'offres, une des premières étapes consiste en la création d'un dossier de travail dans l'environnement infonuagique. Dans ces dossiers classés par année et par date, on retrouve au moins une capture de la page web de publication sur SEAO, ainsi que les fichiers au format PDF des originaux de contrats, de devis

¹ Les options sont des possibilités de prolongation des contrats pour une durée donnée sans republication d'un appel d'offres.

et autres documents. Un tableau de bord permettant le suivi des différentes publications est également mis à jour et contient les informations générales du contrat, telles que le nom du client, le nombre d'heures et la durée.

À partir des contrats originaux et des documents de travail parfois disponibles (il n'y a par exemple pas de documents de travail lorsque les Commissionnaires n'ont pas souhaité poursuivre vers la soumission), nous avons constitué une base de données des caractéristiques techniques des différents contrats via une récolte manuelle dans les documents. Les portées des missions des contrats étant très largement similaires, nous avons pu définir les variables importantes à considérer, elles sont présentées dans le Tableau 4.2.

Tableau 4.2 Variables des caractéristiques techniques des contrats

Variable	Description
Numéro	Numéro client unique du présent contrat
Numéro de référence SEAO	Numéro dans SEAO, peut être le même pour certains renouvellements de contrat
Titre	Le titre de l'AO
Lot	Le lot s'il y a lieu
Client	Le nom du client
Date	La date de publication
Client	Le nom du client
Durée prévue	La durée de base du contrat en mois
Durée prévue des options	La durée des options en mois
Résultat	Le résultat du CCCQ
T_2020, ..., T_2030	Nombre d'heures sur les périodes de décret (1 an)
P1, ..., P13	Nombre d'heures de chacune des primes
Appels	Nombre estimé d'appels (contrat sur appel)
Uniforme	Binaire : faut-il fournir des uniformes
Équipement	Binaire : faut-il fournir de l'équipement spécial
Véhicule	Binaire : faut-il fournir des véhicules
Région	La région d'exécution du contrat
Étalement	L'étalement du contrat (en Km) s'il y a plusieurs lieux

La base de données, construite à partir des documents disponibles depuis 2023, recense 307 contrats. Le principal défi réside dans le fait que de nombreux dossiers de travail ouverts contiennent seulement les fichiers originaux au format PDF et que les appels d'offres non étudiés

par le CCCQ ne peuvent être analysés, faute de documents disponibles. De plus, il nous a été difficile, voire impossible, de retrouver certaines variables clés comme le coût des ressources matérielles, nous nous contentons alors, au premier abord, de considérer des variables binaires globales.

4.4.3 Croisement des données

Une fois les bases de données internes et externes construites, l'objectif est de les croiser afin de lier les caractéristiques techniques des contrats aux résultats d'ouverture des appels d'offres. Pour ce faire, nous utilisons plusieurs variables clés communes aux deux bases de données, telles que le numéro, le numéro de référence SEAO, la date de publication, le titre, le lot et le client (une seule comme clé primaire et les autres comme vérifications avec tolérance), afin d'assurer la liaison entre les contrats et les résultats.

On obtient ainsi une base de données croisée de 272 contrats. Dans 97 % (263) des cas, les résultats d'ouverture sont disponibles et, dans 96 % (262) des cas, les conclusions du contrat sont disponibles.

4.5 Conclusion

Ce chapitre pose le contexte empirique du projet. Nous avons décrit le processus de réponse aux appels d'offres actuellement en place, conformément au formalisme BPMN 2.0. Cette description fait apparaître quatre faiblesses structurelles : une faible intégration d'indicateurs systématiques dans les décisions; un accès difficile aux données; l'absence d'un suivi non biaisé des résultats; et une prospection encore largement manuelle. Nous avons enfin recensé les sources de données mobilisables : la plateforme publique SEAO, dont nous avons extrait 1960 publications entre 2015 et 2026, et la base de données interne reconstituée à partir des dossiers de travail du partenaire depuis 2023 (307 contrats caractérisés), dont le croisement produit une base unifiée de 272 contrats. Nous tenterons de mitiger les faiblesses identifiées en introduisant un outil et des modèles basés sur les données présentées. Le prochain chapitre présente les éléments que nous avons développés au cours de notre recherche.

CHAPITRE 5 Outil et éléments proposés

Dans ce chapitre, nous présentons l’outil développé pour accompagner le processus de réponse aux appels d’offres. Cet outil intègre plusieurs modèles et sous-outils afin de répondre à différents besoins ou faiblesses du processus.

5.1 Présentation générale de l’outil

L'outil proposé dans ce chapitre constitue une réponse aux faiblesses du processus de réponse aux appels d'offres mises en évidence dans le chapitre précédent. Plutôt que de remplacer le travail des gestionnaires par un système automatisé, l'approche retenue vise à concevoir un dispositif d'aide à la décision qui s'intègre aux étapes existantes du processus AS-IS et exploite les données internes et externes disponibles à chaque jalon. Cette posture préserve l'autonomie décisionnelle du gestionnaire tout en lui apportant des éléments de contexte et de quantification jusque-là indisponibles, en particulier lors de décisions complexes telles que l'arbitrage de la pertinence d'un appel d'offres et la détermination du ratio de marge.

Le choix architectural consiste à privilégier une décomposition modulaire de l'outil en cinq éléments complémentaires, plutôt qu'une solution unique. Plusieurs considérations justifient cette orientation. D'une part, les problématiques identifiées au chapitre précédent : prospection insuffisamment outillée, sous-exploitation des fichiers contractuels au format PDF, absence de méthode systématique pour identifier des contrats comparables, et manque d'outil quantitatif pour la tarification relèvent de natures techniques distinctes (récupération web, traitement automatique du langage, apprentissage statistique, visualisation interactive) qui appellent chacune des méthodes spécifiques. D'autre part, la modularité autorise un déploiement progressif et un entretien indépendant des composants, propriété d'autant plus pertinente que la base de données interne du CCCQ est appelée à s'enrichir au fil des soumissions à venir, ce qui permettra un réentraînement des modèles sans remettre en cause l'architecture globale. Cette architecture est aussi une conséquence directe de notre méthodologie de recherche DRM où l'itération conduit au développement ou au redéveloppement de nouveaux éléments après évaluation continue des autres éléments.

L'articulation des éléments suit finalement la chronologie du processus de réponse et est exposée dans la Figure 5.1. L'Élément 1, dédié à la prospection, met en relation les appels d'offres en cours

diffusés sur SEO avec leurs antécédents historiques par résolution d'entité, afin d'enrichir la veille amont du gestionnaire. L'Élément 2 valorise les fichiers PDF des appels d'offres en y extrayant, au moyen d'une architecture de génération augmentée par récupération hiérarchique (RAG), des variables quantitatives relatives aux besoins en ressources matérielles, données qui n'étaient pas disponibles de manière structurée dans les bases internes. L'Élément 3 mobilise ces variables, avec les caractéristiques techniques recensées au Tableau 4.2 pour calculer un score de similarité, via un réseau de neurones entraîné avec des classement réalisés par des experts, entre un contrat à l'étude et l'historique du CCCQ. L'Élément 4 exploite ces voisinages contractuels et la dynamique de marché observée sur SEO pour formuler, grâce à un modèle Learning-to-Rank, une recommandation de ratio de marge. Le dernier élément, l'Élément 5, enfin, expose les sorties des modèles précédents dans une interface destinée aux gestionnaires.

Sur le plan technique, l'ensemble est développé en Python afin d'assurer l'interopérabilité entre les composants et de tirer parti de l'écosystème scientifique mature dont dispose ce langage. L'outil consomme les données issues à la fois de la plateforme SEO et de l'environnement SharePoint interne du CCCQ, puis les expose au gestionnaire selon une logique de tableau de bord, sans automatiser les décisions stratégiques sensibles. La section suivante détaille chacun des éléments en présentant, pour chaque module, les données mobilisées, la méthode retenue ainsi que les premiers résultats obtenus.




Figure 5.1 Schéma d'articulation des éléments développés

5.2 Description des modèles et sous-outils intégrés

Notre outil principal est une combinaison de plusieurs autres outils ou modèles, que l'on appellera éléments, parfois interdépendants, et répondant à des problématiques et objectifs divers. Ceux-ci sont tous développés en Python et permettent l'utilisation des données à plusieurs niveaux. On détaille ces éléments dans le Tableau 5.1.

Tableau 5.1 Éléments développés

Élément	Description	Entrées	Sorties	Moyen
1- Tableau de bord des publications et anticipations	Donne les AOs en cours, les informations et liens si c'est un renouvellement. Anticipe la publication de renouvellements de contrats	<i>Scraping</i> Web des AOs en cours et base de données historique de SEAO	Informations et liens vers les AOs passés si renouvellement.	<i>Scraping Web</i> (Selenium); <i>Entity Resolution</i>
2- RAG pour extraction systématique de données	Extrait de manière rapide et systématique des données des fichier originaux au format PDF	Fichiers de contrat originaux au format PDF	Informations prédéfinis et calcul de scores pour les besoins en ressources.	<i>Hierarchical RAG</i> ; <i>LLM</i>
3- Modèle de calcul de similarités	Permet de trouver les contrats les plus similaires à un contrat étudié	Variables définies de représentation des contrats	Score de similarité entre les contrats	Distances; <i>Neural Networks</i> ; <i>RLHF</i>
4- Modèle de tarification	Donne une estimation du ratio de marge gagnant au plus bas prix	Variables du marché via la BDD SEAO et des caractéristiques des contrats	Le ratio de marge gagnant au plus bas prix	<i>LTR - XGBRanker</i>
5- Outil de visualisation	Pour un contrat donné, permet une visualisation des indicateurs selon des variables choisies	Les sorties des outils et modèles précédents et les variables de choix de visualisation	Des indicateurs visuels permettant l'exploration des données par le gestionnaire	Streamlit

5.2.1 Élément 1 : Anticipation et fouille historique

Ce premier élément vise à améliorer le processus de prospection d'appels d'offres ou de contrats.

Dans un premier temps, on récolte de manière automatique via *Scraping Web*, les appels d'offres en cours qui nous sont potentiellement intéressants en filtrant sur les titres ainsi que sur les codes UNSPSC (*Classification universelle normalisée des produits et des services des Nations Unies (UNSPSC)*, 2026). Pour ces AOs en cours, on souhaite, s'ils sont des renouvellements, retrouver dans la base de données SEAO les caractéristiques et résultats précédents pour afficher des premières informations utiles aux gestionnaires (Prix du dernier contrat, concurrent en place, place du CCCQ lors de l'AO et lien vers la page web). Nous disposons alors des seules informations disponibles lors de la publication pour retrouver des AOs, ces informations, très générales sont : le nom du client, le titre du contrat, la date de publication ainsi que le numéro de référence. Ces champs pouvant légèrement changer pour de mêmes contrats (renouvellement) nous utiliserons des méthodes de résolution d'entité (Règles + SequenceMatcher + Levenshtein + Soundex) pour faire correspondre des appels d'offres comme illustré dans la Figure 5.2.

Dans un deuxième temps, on cherche à permettre l'anticipation de la publication de nouveaux AOs ou permettre la prospection de contrats de gré à gré arrivant à terme. Pour cela, on se base sur la base de données historique des contrats avec leur date de publication ainsi que la durée pour déterminer les dates possibles de republication. On peut ensuite appliquer le même processus que dans notre premier point pour amener des infos utiles.




Figure 5.2 Exemple de liaison de contrats par Entity Matching

Ces deux points permettent de mettre en place un tableau de bord offrant une vision légèrement enrichie du contexte des appels d’offres en cours et à venir. Cela participe alors à l’amélioration des capacités de prospection des gestionnaires.

5.2.2 Élément 2 : Valorisation des données textuelles

Dans cet outil, nous cherchons à valoriser une part importante de données internes, à savoir les fichiers de contrat, devis techniques et autres publiés par le client. Ces fichiers, au format PDF et souvent longs (habituellement entre 100 et 200 pages), contiennent des informations précieuses, tant sur l’appel d’offres que sur les spécificités techniques du contrat. Le principal but ici, est d’extraire des variables quantifiant les besoins en ressources matérielles des contrats, variables qui n’étaient pas disponibles de façon propre et rigoureuse dans les bases de données internes.

5.2.2.1 Retrieval-Augmented Generation

Nous utilisons une structure de *RAG (Retrieval-Augmented Generation)*, combinant un *LLM* et les documents, pour extraire et estimer les ressources requises par le soumissionnaire. Ces ressources, que l’on sépare en trois catégories, concernent les besoins en uniformes, équipements et en véhicules. L’utilisation d’un *LLM* pour la récupération permet alors de considérer des cas flous où une ressource est abordée dans le texte mais définie comme étant fournie par le client et non le soumissionnaire (Raini, 2024).

La structure que nous avons développée est illustrée dans la Figure 5.3.




Figure 5.3 Structure générale du RAG


Premièrement, on utilise la librairie Python *PyMuPDF* pour lire les fichiers au format PDF. Cette librairie est constituée de multiples outils de vision, de reconnaissance de caractères et de modèles lui permettant de séquencer le texte en paragraphes et de les labelliser (titre de section, texte, liste, pied-de-page, etc.) (PyMuPDF, 2024/2026). Les contrats que nous traitons étant très structurés, cela nous apporte des informations importantes que l'on utilisera après.

Avec les informations récupérées, on constitue les *chunks* (bouts de textes) qui seront utilisés lors des phases de récupération et de génération. On utilise alors la structure hiérarchique du contrat pour créer des *chunks* représentant les différentes sections avec différents niveaux (par exemple « 1. » est de niveau 0, « 1.1 » est de niveau 1 et « 1.1.1 » de niveau 2). Cette segmentation plus logique du texte permet alors une meilleure efficacité du *retrieval* et de la méthode en général (Lu et al., 2025). Un niveau plus bas contient alors tous les *chunks* enfants de niveaux plus hauts. Une étape de prétraitement permet, à l'aide d'algorithmes développés de récupérer des sections manquantes ou mal libellées.

Le vocabulaire des contrats de sécurité étant technique et spécifique, nous privilégierons l'*embedding* de ces chunks en utilisant des vecteurs creux (*sparse vectors*), augmentés du vocabulaire métier propre à ce domaine (Iida & Okazaki, 2022). Cette approche est efficace pour

récupérer les informations souhaitées et performe mieux que les *embeddings* classiques denses sur des corpus spécialisés (Mandikal & Mooney, 2024).

Ensuite, on récupère les *chunks* pertinents. Pour cela, on se base sur les vecteurs creux des *embeddings* et de notre *query* enrichie par le vocabulaire métier (question posée). On utilise l’algorithme BM25 (Robertson & Zaragoza, 2009) couplé à la hiérarchie pour comparer les *chunks*, la méthode complète est présentée dans l’Annexe E. La Figure 5.4 présente la performance accrue de cette méthode par rapport à des méthodes classiques en termes de taux de récupération de l’information par rapport à la longueur des *chunks* qui influent directement sur les performances futures du *LLM* lors de la phase de génération (en termes d’hallucinations notamment).

Figure 5.4 Comparaison des méthodes de *retrieval*

Une fois les *chunks* récupérés, on construit le *prompt* que l'on va passer au *LLM*. Si des chunks sont issus d'addenda, c'est-à-dire de corrections ou précisions, on précise de considérer cette information en cas de doutes. On ajoute des règles critiques ainsi que le schéma de réponse que le *LLM* doit utiliser. Le modèle de langage que nous utilisons est le modèle *Ministral-3-14B-instruct* (*GGUF, Q5_K_M*) un modèle frugal et particulièrement adapté à nos conditions. Les résultats, en termes d'éléments récupérés (besoins en uniformes, équipements ou véhicules), pour 50 contrats sont présentés dans le Tableau 5.2.

Tableau 5.2 Résultats d'extraction par RAG

Réel \ Extraction	True	False
True	263 (88 %)	5 (1 %)
False	41 (13 %)	.

On constate alors une performance très satisfaisante, avec une précision de 87 % et un rappel de 98 % sur les éléments identifiés de 50 contrats.

5.2.2.2 Évaluation quantitative des besoins en ressources

Après avoir extrait une liste des besoins en ressources, on quantifie les besoins dans chaque catégorie (uniformes, équipements et véhicules). Pour cela, on constitue un dictionnaire assez exhaustif de coûts (en dollars) pour des besoins récurrents identifiés. Le but ici n'est pas de quantifier exactement le coût financier mais de constituer une base de comparaison entre les contrats. Depuis la liste de ressources extraite et à l'aide de la librairie de *NLP spaCy* (*Stargazers · Explosion/spaCy*, 2026), on assigne chaque ressource à son coût en prenant en compte les correspondances parfaites ou partielles auquel cas on distribue les coûts. La somme nous donne le score correspondant aux besoins en ressources.

Il nous est possible d'évaluer notre méthode pour la catégorie relative aux uniformes. En effet, la distribution des scores correspond au coût facturé par les Commissionnaires pour différents types d'uniformes comme illustré dans la Figure 5.5.




Figure 5.5 Distribution des scores uniformes (orange) comparée aux prix facturés par le CCCQ (bleu)

5.2.3 Élément 3 : Calcul de la similarité des contrats

Dans cet élément, on développe une manière de comparer les contrats afin de pouvoir récupérer les contrats les plus similaires. Les variables que nous allons considérer sont consignées dans le Tableau 5.3. Toutes les variables continues ont été normalisées par minimum-maximum.

Tableau 5.3 Variables utilisées pour la similarité des contrats

Variables	Types	Commentaires
Région	catégorie	16 régions
Type de client	catégorie	8 types
Nom du client	chaîne de caractères	
Durée	flottant	En mois
Date de publication	date	
Prix	flottant	Prix du décret
Appels	flottant	Nombre d'appels par an
Heures	flottant	Nombre d'heures par an
Véhicules	flottant	Score RAG de besoins en véhicules
Matériel	vecteur[flottant]	Scores RAG de besoins en uniformes et équipements
Nature	vecteur[flottant]	Vecteurs des heures de primes

Dans un premier temps, on définit des distances entre les variables de deux contrats :

- Région : On définit une matrice de distance à partir de caractéristiques des régions (urbanisation, population, étendue);
- Type de client : On définit une matrice de distance selon les caractéristiques des clients, par exemple « Cégeps » et « Centres de services scolaires » sont proches;
- Nom du client : Comparaison de séquences;
- Durée, Heures, Prix, Matériel : Simple distance euclidienne;
- Date de publication : Calcul du delta puis décroissance logarithmique;
- Nature : Combinaison de distances de Jaccard binaire et pondérée afin de capter les correspondances en termes de primes présentes ainsi que leur quantité; et
- Véhicules, Appels : Distance euclidienne avec pénalisation en cas de non-égalité binaire (Eq 5.1). Les variables en question influençant beaucoup le type de contrat (présence de véhicules ou d'heures sur appel).

$$d(v1, v2) = \begin{cases} 0 & \text{si } v1 = v2 = 0 \\ |v1 - v2| & \text{si } v1 \neq 0 \text{ et } v2 \neq 0 \\ \lambda |v1 - v2| & \text{sinon} \end{cases} \quad (5.1)$$

Toutes les distances (sauf en cas de pénalités) donnent un résultat entre 0 et 1, notre but est maintenant de les combiner pour obtenir une distance représentant la similarité globale entre deux contrats. La méthode que nous avons choisie de suivre consiste à combiner une approche naïve accordant un poids initial à chacune des distances avec une approche d'apprentissage machine pour peaufiner ces poids.

Nous avons donc d'abord accordé des poids unitaires à chacune des distances et entraîné un modèle de réseau neuronal simple (3,2). À ce stade, l'entraînement est très rapide. Ensuite, on construit une base de données de classement en prenant un contrat et 3 autres parmi les 15 les plus similaires, et en demandant à un employé de les classer du plus au moins similaire. Cette base, constituée d'environ 300 itérations, permet de réentraîner le réseau par apprentissage par récompense pour ajuster les poids pertinents à l'aide de la perte de Bradley-Terry et de l'implémentation de l'algorithme RankNet (Burgess et al., 2005) pour comparer les classements.

La

Figure 5.6 présente les performances du modèle avant et après le renforcement. La part de trios exacts augmente significativement. De même, on constate une augmentation du coefficient de corrélation de Spearman-Rho, ce qui confirme le fait que le modèle a intégré le raisonnement de classement de l'humain.




Figure 5.6 Similarité après réentraînement

5.2.4 Élément 4 : Modèle de tarification

Dans ce modèle, nous allons nous appuyer sur les outils développés précédemment pour, à partir des données historiques, construire un modèle visant à prédire la marge à appliquer afin de battre les autres soumissionnaires dans un appel d'offres au plus bas soumissionnaire.

Le but de notre modèle est de considérer à la fois l'environnement et le contexte concurrentiel du marché actuel ainsi que les caractéristiques techniques propres aux contrats.

5.2.4.1 Caractéristiques du contrat

Dans notre modèle, pour prendre en compte les caractéristiques techniques des contrats, nous utiliserons le modèle de similarité développé précédemment. Ainsi, nous extrairons les contrats les plus similaires afin d'utiliser les résultats lors des appels d'offres associés.

Les variables que nous retiendrons sont les ratios de marge gagnante ainsi que la date pour les appels d'offres de ces k contrats similaires. Cependant, ces appels d'offres peuvent avoir eu lieu à des dates plus ou moins anciennes, dans un marché qui peut ne plus ressembler à celui d'aujourd'hui. C'est pourquoi nous allons devoir prendre en compte l'évolution des dynamiques du marché dans lequel nous évoluons.

5.2.4.2 Dynamique du marché

Une première prise en compte de la dynamique du marché consiste en l'actualisation des ratios de marge gagnante pour les contrats similaires. Pour cela, on se base sur l'évolution des ratios de marges gagnantes au cours du temps. Pour un appel d'offres publié à la date t , on considère comment le ratio gagnant se plaçait par rapport au marché à ce moment pour en déduire le ratio autour duquel il devrait se placer par rapport à la moyenne actuelle M_T comme illustré dans la Figure 5.7. Simplement, on calcule le ratio actualisé R_T par simple proportionnalité (Eq 5.2).

$$R_T = \frac{R_{t-1} \cdot M_T}{M_{t-1}} \quad (5.2)$$

Ainsi, on actualise les ratios de marge gagnante pour les contrats similaires.




Figure 5.7 Évolution du marché – Exemple d’actualisation à la date T pour un contrat publié à la date t_1

La deuxième prise en compte de la dynamique de marché consiste à rechercher les derniers appels d’offres ainsi que leurs résultats afin de constituer une moyenne des ratios gagnants actuels.

Les deux entrées que nous allons utiliser ultérieurement dans notre modèle sont donc :

- Les ratios gagnants des contrats similaires, actualisés au marché actuel ; et
- Les ratios gagnants des derniers contrats.

5.2.4.3 Modèles

Le problème de tarification dans les appels d’offres est étudié depuis un certain temps. Les premiers travaux, réalisés par Friedman et Gates, abordent le problème d’un point de vue statistique en étudiant la distribution des marges appliquées par les différents concurrents pour établir des fonctions de densité de probabilité de gain (Friedman, 1956; Gates, 1967). L’étude de ces modèles statistiques a continué d’évoluer notamment avec Carr (1982), Skitmore (2002, 2004, 2014) et consort (Skitmore et al., 2007; Ballesteros-Pérez & Skitmore, 2017), afin de mieux modéliser la distribution des offres concurrentes et d'affiner l'estimation de la probabilité de gain conditionnelle à une marge donnée. Cependant, ces modèles reposent sur des hypothèses fortes : indépendance des soumissionnaires, stationnarité du marché, et disponibilité d'un grand nombre d'offres comparables qui se vérifient rarement dans la pratique et limitent leur capacité à intégrer le contexte technique propre à chaque contrat.

Pour pallier ces limites, la littérature s'est progressivement tournée vers des approches issues de la recherche opérationnelle, puis de l'apprentissage automatique. Les réseaux de neurones artificiels (Christodoulou, 2010; Moselhi & Hegazy, 1993) ont ensuite démontré une meilleure capacité à modéliser ces relations complexes, au prix d'un besoin important en données d'entraînement et d'une faible interprétabilité, des contraintes particulièrement pénalisantes dans notre contexte d'appels d'offres où l'historique exploitable est restreint. Les approches par raisonnement à partir de cas (*Case-Based Reasoning*) ont également été explorées (Chua et al., 2001) pour exploiter explicitement la similarité avec les contrats passés, mais elles restent sensibles à la qualité de la mesure de similarité et n'intègrent pas naturellement la dynamique temporelle du marché. Plus récemment, les méthodes d'ensemble fondées sur les arbres de décision, forêts aléatoires et *gradient boosting* se sont imposées comme un compromis intéressant entre performance, robustesse au surapprentissage et capacité à fonctionner avec des jeux de données de taille modérée (Chen & Guestrin, 2016).

5.2.4.4 Modèle Learning to Rank

Dans notre cas, la base de données dont nous disposons compte environ 120 appels d'offres exploitables, ce qui exclut les architectures profondes et fragilise la formulation classique du problème en régression sur la marge absolue. Nous nous tournons donc vers une approche de *Learning to Rank* (LTR) fondée sur *XGBoost* (Burges et al., 2005). La reformulation du problème, non plus comme la prédiction d'une valeur de marge mais comme un classement relatif des offres potentielles entre elles, présente plusieurs avantages : elle exploite mieux les comparaisons par paires que permettent les contrats similaires identifiés à l'étape précédente, elle est moins sensible aux variations absolues de marges induites par la dynamique du marché, celles-ci étant déjà partiellement neutralisées par l'actualisation décrite en équation (5.2), et elle permet plus efficacement l'utilisation d'un volume de données limité. *XGBoost* apporte par ailleurs la capacité à modéliser les interactions non linéaires entre les caractéristiques du contrat, les ratios actualisés issus des contrats similaires et les ratios des derniers appels d'offres remportés, tout en conservant une interprétabilité relative grâce à l'analyse des importances de variables.

Le modèle, décrit dans le schéma de la Figure 5.8, se base sur une grille de marges (ratios) candidates plausibles (de 1,05 à 3,00) ainsi que leur placement par rapport aux marges des derniers contrats ou des contrats similaires ; ce sont les neuf paramètres du modèle de classement. On

identifie alors la pertinence d'une offre, l'offre la plus haute possible gagnante étant l'offre la plus pertinente puisqu'elle permet de gagner le contrat, tout en appliquant la marge maximale, les offres non gagnantes sont par définition non pertinentes.

Pour évaluer notre modèle, nous nous basons sur une base de référence des Commissionnaires. Cette base de données contient 54 appels d'offres auxquels les soumissionnaires ont participé. Nous calculons les performances de référence des Commissionnaires sur les 20 derniers appels d'offres, ceux-ci constituent notre ensemble de test. Pour notre modèle, pour chacun des contrats appartenant à l'ensemble de test, nous entraînons notre modèle sur l'ensemble des contrats antérieurs (*Leave-One-Out* chronologique), ce qui correspond aux conditions réelles de potentielle utilisation du modèle.

Les indices de performance que nous utilisons sont consignés dans le Tableau 5.4.

Tableau 5.4 Indices de performance du modèle de tarification

Indice de performance	Formule (pour N appels d'offres)
Rank Score (RS)	$\sum_i^N \frac{1}{r_i} \text{ avec } r_i \text{ le rang} \quad (5.3)$
Mean Rank (MR)	$\frac{1}{N} \sum_i^N r_i \text{ avec } r_i \text{ le rang} \quad (5.4)$
Win rate (WR)	$\frac{1}{N} \sum_i^N (r_i = 1) \text{ avec } r_i \text{ le rang} \quad (5.5)$
Mean Distance (MD)	$\frac{1}{N} \sum_i^N m_i - w_i \text{ avec } m_i \text{ la marge prédite} \\ \text{et } w_i \text{ la marge gagnante} \quad (5.6)$
Cumulative Distance (CD)	$\sum_i^N m_i - w_i \text{ avec } m_i \text{ la marge prédite} \\ \text{et } w_i \text{ la marge gagnante} \quad (5.7)$
Dollars Gains (DG)	$\sum_{r_i=1}^N (m_i - 1)p_i \text{ avec } m_i \text{ la marge prédite} \\ \text{et } p_i \text{ le prix du contrat} \quad (5.8)$


On compare les résultats des indices de performances de plusieurs modèles et méthodes, dans ce même ensemble de test, par rapport aux résultats de référence des Commissionnaires dans le Tableau 5.5.

Tableau 5.5 Résultat des différents modèles

Modèle	RS↑	MR↓	WR↑	MD↓	CD↓	DG↑	Variables
Référence CCCQ	0,26	6,20	15 %	0,362	7,25	2,17 M\$	/
Gates-Friedman ²	0,18	8,80	17 %	0,412	8,29	0,72 M\$	Distribution des marges historiques
Means	0,35	6,50	25 %	0,318	6,36	1,50 M\$	Contrats similaires et récents, pas d'ajustement au marché
Regression	0,50	4,15	40 %	0,250	4,99	1,59 M\$	Contrats similaires et récents, moyennes ajustées au marché
LTR	0,49	3,55	40 %	0,280	5,58	3,52 M\$	Contrats similaires et récents, variables ajustées au marché

L'analyse des performances démontre la supériorité de l'approche sélectionnée, *Learning to Rank* (LTR), qui parvient à maximiser le taux de réussite et la rentabilité. Si la stratégie de référence (CCCQ) et les méthodes statistiques historiques parviennent difficilement à atteindre des taux de victoire (WR) compris entre 15 % et 25 %, l'utilisation du *Machine Learning* (Régression et LTR) permet d'atteindre un taux de victoire de 40 %. Cependant, une différence sépare la Régression du LTR : bien que la Régression soit très douée pour « viser juste » et minimiser l'écart absolu par rapport à la marge gagnante (MD de 0,250), elle génère des gains financiers faibles (1,59 M\$). En effet, la régression, fondée uniquement sur les moyennes des marges gagnantes des derniers contrats et des contrats similaires, utilise une erreur symétrique qui la pousse à sous-évaluer les offres afin d'assurer la victoire au détriment du profit. À l'inverse, le modèle LTR s'impose comme le meilleur modèle avec de bons gains financiers (3,52 M\$) et le meilleur classement moyen (MR de 3,55). En évaluant des scénarios sur une grille de candidats (de 1.05 à 3.00) plutôt qu'en prédisant une valeur absolue, le LTR exploite parfaitement le petit volume de données et comprend la notion asymétrique de l'enchère : il ne cherche pas simplement le prix le plus bas, mais identifie avec précision l'offre la plus haute possible permettant de battre les concurrents, maximisant ainsi directement la rentabilité de l'entreprise.

² On choisit le modèle de Gates en prenant un seuil de probabilité de gain de 80 %, seuil choisit après réalisation d'une analyse de sensibilité.



Nouveau contrat

Marges gagnantes derniers contrats : M_{last}
Marges gagnantes contrats similaires : $M_{similar}$

Base de données historique

Features

$$\begin{aligned} x_0 &= g \\ x_1 &= \overline{M_{last}} \\ x_2 &= \overline{M_{similar}} \\ x_3 &= g - \overline{M_{last}} \\ x_4 &= g - \overline{M_{similar}} \\ x_5 &= |g - \overline{M_{last}}| \\ x_6 &= |g - \overline{M_{similar}}| \\ x_7 &= \frac{g}{\overline{M_{similar}}} \\ x_8 &= \frac{g}{\overline{M_{last}}} \end{aligned}$$

Prédictions relevance

g	1.06	1.15	1.33	1.34	...	2.99	3.00
r	6	15	33	0	...	0	0

Marge prédite

Figure 5.8 Schéma du modèle de tarification

Ainsi, nous avons développé un modèle capable de prédire une marge gagnante et rentable en utilisant les caractéristiques des contrats, mesurées par la similarité, ainsi que les caractéristiques et dynamiques du marché.

5.2.5 Élément 5 : Outil de visualisation

L'ensemble des éléments précédemment développés doit pouvoir s'intégrer au processus de réponse aux appels d'offres. Ces données sont ainsi intégrées dans un outil consultable et interactif pour les gestionnaires. Cet outil est conçu comme une application, de sorte qu'il soit potentiellement intégré à l'avenir dans un environnement interne.

Une première partie ou page de cet outil est l'élément 1. Cette page (Figure 5.9) est utile lors de la phase amont du processus : la prospection de nouveaux contrats. Elle permet au gestionnaire d'avoir un état des lieux rapide des appels d'offres en cours et à venir, et de saisir rapidement ceux avec le plus de potentiel.

Cette page donne accès aux contrats en cours (premier tableau) ainsi qu'aux renouvellements à venir (deuxième tableau). La sélection d'un avis en cours est possible. Le bouton « Analyser ce contrat » permet de passer directement à l'analyse en préremplissant les champs d'informations générales de la page d'analyse.

La deuxième partie, la page d'analyse (Figure 5.10), permet de sélectionner un appel d'offres et de renseigner les caractéristiques techniques de celui-ci. On utilise alors les outils et modèles développés lors de notre projet de recherche pour afficher les différents indicateurs et menus d'exploration utiles aux décisionnaires dans leur décision de soumission ainsi que dans la construction de leur offre financière.

Un premier exemple d'utilisation est le sous-menu « contrats passés correspondants » qui permet de retrouver les appels d'offres précédents du contrat dont le renouvellement est à l'étude. Il est alors possible de consulter la page correspondante à l'AO sur le site SEAO via les liens récupérés, mais aussi d'afficher directement les résultats, les offres et les marges appliquées, ainsi que le calcul des marges actualisées. On permet aussi l'affichage des données brutes disponibles, au format *json*.




Figure 5.9 Première page de l'outil (AOs en cours)

Deuxièmement, on récupère et affiche les contrats similaires de la même façon.

Enfin, une partie d'analyse générale est disponible pour étudier le contexte du contrat. Des graphes permettent d'afficher les marges (réelles et actualisées) pour les derniers contrats, les contrats similaires ainsi que les contrats passés. On affiche ensuite les concurrents potentiels, leur taux de participation aux appels d'offres émis par le client, leur taux de victoire avec ce client en cas de participation, les cinq dernières marges appliquées, ainsi que la tendance générale de tarification du concurrent au cours de l'année précédente. Cela nous permet d'évaluer la dangerosité d'un concurrent selon son affinité avec le client ainsi que son agressivité actuelle. Les derniers

indicateurs affichés sont les moyennes des marges pour les derniers contrats, les contrats similaires et les contrats passés, ainsi que la recommandation de marge calculée par le modèle de tarification développé.




Figure 5.10 Deuxième page de l'outil (Analyse)

5.3 Intégration dans le processus

L'intégration de notre outil au processus permet l'intégration des données au processus visé chez notre partenaire. Pour souligner les changements apportés au processus, nous utiliserons un code couleur pour en visualiser la nature. Les activités modifiées seront en jaune, les nouvelles activités en vert et celles seulement modifiées chronologiquement en bleu (Mosser, 2020).

La première partie de l'outil permet de transformer totalement la posture de prospection pour de nouveaux appels d'offres. Plutôt que d'attendre des alertes par courriel configurées sur la plateforme SEAO ou de consulter celle-ci de temps à autre, l'entièreté des AOs en cours est visuellement accessible rapidement. De plus, des informations clés comme la possible taille (prix) de l'AO, le concurrent en place et la position du CCCQ lors du dernier AO en cas de renouvellement permettent de rapidement visualiser les AOs à fort impact. Enfin, on permet une posture d'anticipation en exposant les futurs AOs potentiels ou les contrats de gré à gré arrivant à terme. Cela peut permettre aux gestionnaires de mieux privilégier le potentiel de réponse en tenant compte du contexte actuel et futur du marché des ouvertures d'appels d'offres. On apporte alors un contexte global pour appuyer la décision de soumissionner.

La deuxième partie de l'outil permet de transformer le processus d'analyse et de construction de l'offre. Elle inclut maintenant la donnée qui auparavant, n'était pas considérée dans le processus faute de disponibilité ou d'outil permettant son utilisation. Lors de la phase d'analyse d'une offre illustrée dans la Figure 5.11, on ajoute maintenant une étape visant à la sauvegarde systématique des données relatives aux contrats, données primordiales pour constituer une base de données mettant en relation les contrats et les résultats des appels d'offres. Ce sont aussi ces données qui permettent ensuite une analyse approfondie et l'apport d'indicateurs cruciaux aux gestionnaires. Après, lors de la phase de calcul de l'offre financière illustrée dans la Figure 5.12, c'est-à-dire le calcul du ratio de marge à appliquer, le gestionnaire peut maintenant s'appuyer sur les données historiques ainsi que sur des modèles pour établir de manière plus quantitative la stratégie optimale à adopter. Ces indicateurs viennent appuyer la décision en apportant le contexte historique, le contexte technique ainsi que la dynamique du marché actuel.




Figure 5.11 Processus d'analyse (TO-BE)




Figure 5.12 Processus d'analyse de scénarios (TO-BE)

5.4 Déploiement

Le déploiement de l'outil dans l'environnement de notre partenaire s'effectue par étapes, et les premiers travaux en cours concernent l'Élément 1 (et une partie de l'Élément 5). L'Élément 1, qui constitue la première page de l'outil graphique (Élément 5) dédiée à la prospection et à l'anticipation des renouvellements, est en cours de déploiement au sein de l'infrastructure Azure des Commissionnaires.

L'architecture retenue s'articule autour de deux briques principales. D'une part, une couche de stockage et d'orchestration des données, mise en place dans le lac de données du partenaire (Azure Data Lake Storage Gen2), centralise l'ensemble des données nécessaires à l'outil. Les données relatives aux résultats d'ouverture des appels d'offres sont actualisées selon une fréquence hebdomadaire, calée sur le rythme de publication observé sur la plateforme SEAO, tandis que les avis en cours sont récupérés quotidiennement afin d'assurer une vision à jour des opportunités du marché.

D'autre part, l'application elle-même est conteneurisée à l'aide de *Docker* et hébergée dans l'environnement Azure du partenaire. Ce choix architectural répond à plusieurs objectifs. Il permet d'inscrire la maintenance et l'évolution de l'outil dans une logique DevOps, en facilitant l'intégration et le déploiement continus des prochaines versions. Il garantit également une disponibilité homogène de l'application pour l'ensemble des utilisateurs de l'environnement, indépendamment de leur poste de travail, et assure une isolation propre des dépendances techniques nécessaires à l'exécution des composants Python développés.

Ce premier déploiement constitue ainsi une preuve de concept et un socle sur lequel les éléments suivants de l'outil pourront progressivement être intégrés en production.

5.5 Conclusion

Dans ce chapitre, nous avons décrit l'outil ainsi que les éléments que nous proposons pour intégrer la donnée au processus de réponse aux appels d'offres étudié chez notre partenaire. Nous avons aussi examiné comment cet outil pourrait être intégré chez notre partenaire et comment il modifie les processus en place. Dans le chapitre suivant, nous testerons notre outil ainsi que ses éléments en l'appliquant à des appels d'offres potentiels disponibles dans notre base de données historique.

Ceci nous permettra de comparer nos recommandations et indicateurs aux décisions réelles prises afin d'évaluer l'utilité de notre outil.

CHAPITRE 6 Expérimentations

L'objectif dans ce chapitre est de procéder à une évaluation de la pertinence et des performances de notre outil en l'utilisant dans des conditions réelles passées. On utilise notre base de données historique pour évaluer notre outil à différents instants, traduisant des contextes et situations diverses. Nous pouvons ainsi identifier les faiblesses, points forts et potentielles améliorations nécessaires.

6.1 Appels d'offres utilisés

Pour notre expérimentation, on utilise les données historiques disponibles dans notre base de données, ces données contiennent des appels d'offres sur lesquels le CCCQ a porté son attention auquel cas nous pourrions faire une analyse complète, mais aussi des appels d'offres non considérés par le CCCQ, cas dans lequel nous ne pouvons pas aller plus loin que l'étude de notre outil de prospection. Lors de l'étude d'un appel d'offres publié, nous considérons alors toutes les données disponibles avant la date de publication moins deux mois, durée moyenne de mise en ligne des résultats pour un appel d'offres. Cette période constitue en effet une zone de publication de résultats normalement invisible puisque les résultats des contrats publiés de cette zone ne peuvent avoir été publiés avant la date de notre étude. Ce schéma est illustré dans la Figure 6.1.




Figure 6.1 Schéma des données utilisées lors d'une expérimentation

6.2 Prospection et anticipation

Le but de cette partie est d'évaluer notre outil de prospection (la page une de notre outil), pour cela, nous allons vérifier que les informations calculées et affichées soient correctes. Dans cette partie, les données techniques des contrats ne sont pas utiles pour les champs que nous cherchons à vérifier, nous ne sommes donc pas dépendants de la base de données interne du CCCQ et pouvons

alors considérer plus d'appels d'offres issus de la base de données SEAO. On s'intéresse alors à l'entièreté des appels d'offres publiés sur l'année 2025 soit 179 contrats.

Premièrement, on cherche à vérifier la récupération des contrats antérieurs en cas de renouvellement. On obtient 60 contrats pour lesquels notre algorithme d'*Entity Matching* a trouvé des contrats passés. La concordance est de 92 % (101 sur 110), seuls quelques contrats couplés par l'algorithme n'ont pas de liens directs. Le Tableau 6.1 présente quelques exemples trouvés.

Tableau 6.1 Résultats de couplage par *Entity Matching*

Titre	Date	Prix
Service d'une agence de sécurité pour la surveillance de l'unité sanitaire -- Ville de Québec	févr-25	
Service d'une agence de sécurité pour la surveillance de l'unité sanitaire mobile - Place du Carré Lépine -- Ville de Québec	juil-23	
Service d'une agence de sécurité pour la surveillance de l'unité sanitaire mobile - Place du carré-Lépine -- Ville de Québec	mai-24	
Service d'agence de sécurité Centre Jean-Claude-Malépart 2025-2026 -- Ville de Montréal - Service de l'approvisionnement	avr-25	350 666
Services d'agence de sécurité au Centre Jean-Claude Malépart -- Ville de Montréal - Service de l'approvisionnement	mars-24	381 671
Service de sécurité pour l'immeuble sis au 303, rue Notre-Dame Est, Montréal, Complexe CDL -- Société d'habitation et de développement	avr-25	
Services de sécurité pour l'immeuble situé au 303, rue Notre-Dame Est à Montréal -- Société d'habitation et de développement	mars-23	
Services de sécurité pour l'immeuble situé au 303, rue Notre-Dame Est (Complexe CDL) -- Société d'habitation et de développement	mars-22	
Service de sécurité pour un bât., divers parcs et événements de la ville -- Ville de Salaberry-de-Valleyfield	avr-25	96 834
Service de sécurité pour un bâtiment, divers parcs et événements de la ville -- Ville de Salaberry-de-Valleyfield	févr-25	
Fourniture de services de sécurité pour la Ville de Longueuil -- Ville de Longueuil	mai-25	580 28
FOURNITURE DE SERVICES DE SÉCURITÉ POUR LA VILLE DE LONGUEUIL -- Ville de Longueuil	avr-22	591 956
Service d'une agence de sécurité Bibliothèque Paul-Aimé-Paiement (2019-289) -- Ville de Québec	juin-25	
Service d'une agence de sécurité (gardien) - bibliothèque Paul-Aimé-Paiement. -- Ville de Québec	mai-24	
Services de sécurité de Blainville en fête et l'OSM dans les parcs, édition 2025 -- Ville de Blainville	août-25	
Services de sécurité de Blainville en fête édition 2024 -- Ville de Blainville	juil-24	
Fourniture sur demande de service d'agents de sécurité pour le Service des loisirs et de la culture -- Ville de saint-georges	août-25	58 723
Fourniture sur demande de service d'agents de sécurité pour le Service des loisirs et de la culture -- Ville de saint-georges	sept-23	73 239
Fourniture sur demande de service d'agents de sécurité pour le Service des loisirs et de la culture -- Ville de saint-georges	nov-24	77 838
Fourniture sur demande de service d'agents de sécurité pour le centre de ski -- Ville de saint-georges	nov-23	26 869
Service de gardiennages dans divers lieux de l'arrondissement Lachine -- Ville de Montréal - Arrondissement de Lachine	déc-25	375 611
Service de gardiennage pour différentes bâtisses de l'arrondissement Lachine -- Ville de Montréal - Arrondissement de Lachine	déc-22	319 48

Deuxièmement, on vérifie les anticipations. En 2025, 177 contrats avaient une date de renouvellement possible (fin de la période de base ou fin de la période de base + options). Parmi ces 177 contrats, 21 % (38) ont bien été republiés en tant que nouveaux appels d'offres à des périodes similaires en 2025.

6.3 Analyses

Cette partie vise à évaluer les indicateurs donnés par notre outil ainsi que le modèle de tarification lors de l'analyse d'un appel d'offres.

6.3.1 Évaluation du modèle de tarification général

En utilisant le schéma de données décrit précédemment, nous étudions les appels d'offres émis sur une période d'un an, de février 2023 à mars 2024. Ces contrats représentent tous ceux présents dans notre base de données pour cette période, et pour lesquels nous disposons de données suffisantes pour permettre la prédiction via notre modèle. En d'autres termes, le CCCQ y a au moins accordé de l'attention, ce qui a conduit au téléchargement et à l'archivage des fichiers de contrats originaux.

Pour ces 57 appels d'offres étudiés, le nombre de données d'entraînement pour le modèle est de 31 pour l'AO le plus ancien à 117 pour le plus récent. Les résultats sont consignés dans le Tableau 6.2.

On notera qu'une marge prédite par le modèle peut en pratique être non pertinente, en effet, en deçà d'un certain seuil ($\sim 0,3$), le contrat n'est pas viable économiquement pour le CCCQ. Cela est directement dû à la méthode de calcul, la marge est en réalité le ratio de marge (Eq 4.1) qui ne prend pas en compte tous les coûts fixes. On calcule alors les profits en soustrayant ce seuil à la marge appliquée (Eq 6.1).

$$\text{Profit} = \text{Prix minimum régi par le décret} \left(\text{Ratio de marge} - (1 + \text{seuil}) \right) \quad (6.1)$$

Ces marges sont colorées en orange dans le tableau et, même si leur valeur quantitative n'est pas pertinente, elles peuvent constituer un signal que l'appel d'offres est trop compétitif pour être viable pour le CCCQ.

Sur les 57 appels d'offres, le modèle en remporte 59 % (33 premiers rangs). Cependant, dans 48 % (16 AOs), la marge est trop basse pour être profitable. Si l'on pose un seuil de participation pour ne considérer que les marges profitables, le modèle obtient un taux de victoire de 25 % (15 premiers rangs), avec un profit d'environ 9 M\$. Sur les 40 participations alors considérées, le modèle obtient 15 premiers rangs, 7 deuxièmes places et 6 troisièmes places, ce qui le place dans le top 3 dans 70 % des cas.

Tableau 6.2 Résultats du modèle pour les AOs de la période 2023-2024

Appel d'offres	Date	N_train	Modèle (marge)	Dernier ga- gnant (marge)	Prix	Rang	Profit	Modèle
1000529_1695032	f-23	31	1,17	2,00	607 852	1	-79 021	
87390_1697297	m-23	32	1,70	1,53	115 545	3		
CISSSO-2324-011-S_1701134_Lot 01	m-23	33	1,60	1,48	7 428 380	5		
CISSSO-2324-011-S_1701134_Lot 02	m-23	33	1,60	1,47	1 035 180	3		
APL00013178_1700907	m-23	33	1,73	1,87	2 586 589	1	1 112 233	
40366100_1704866	m-23	37	1,21	1,52	1 676 282	1	-150 865	
SE-2023-5632-001-AOP_1707085_Lot 08	m-23	38	1,29	1,52	76 856	1	-769	
DG-2023-001_1707077	m-23	38	1,29	1,65	188 907	1	-1 889	
AOP20230329NH-SM-SEC-ETE_1707964	m-23	40	1,49	1,29	195 898	3		
CL_222300-7_1708984	m-23	41	1,50	1,45	1 322 040	2		
44533253_1709697	a-23	42	1,46	1,39	1 261 991	2		
44533278 et autres_1710129_Lot 04	a-23	43	1,18	1,40	1 106 255	1	-132 751	
44533278 et autres_1710129_Lot 03	a-23	43	1,19	1,33	381 786	1	-41 996	
44533278 et autres_1710129_Lot 06	a-23	43	1,28	1,38	147 914	1	-2 958	
44533278 et autres_1710129_Lot 07	a-23	43	1,19	1,35	185 203	1	-20 372	
DR23-PUB-061_1711014	a-23	48	1,17	1,67	195 196	1	-25 375	
23-6108_1711753	a-23	49	1,51	1,53	1 488 735	1	312 634	
367100113_1717268	a-23	50	1,43	1,03	41 968	4		
87891_1720434	m-23	51	1,30	1,59	171 949	1		
87890_1719422	m-23	51	1,28	1,64	310 463	1	-6 209	
87919_1721393	m-23	53	1,41	1,85	1 586 999	1	174 570	
SER-SÉCURITÉ 2023_1722747	m-23	54	1,34	3,21	485 280	1	19 411	
88123_1730043	j-23	55	1,44	1,75	288 793	1	40 431	
6000025686_1735234	j-23	56	1,55	1,31	360 721	1	90 180	
2022/23-226_1733867	j-23	57	1,48	2,44	137 425	1	24 737	
CI-4485_1742771	j-23	58	1,55	1,37	2 518 464	3		
88409_1743089	j-23	59	1,43	1,96	573 256	1	74 523	
2023-7553-50-01_1692797_Lot 3	j-23	60	1,63	3,80	3 335 645	1	1 100 763	
2023-7553-50-01_1692797_Lot 2	j-23	60	1,63	3,81	1 566 903	1	517 078	
AO-2023-01_1747549	j-23	64	1,26	1,48	921 532	1	-36 861	
CSI2324-021_1749120	j-23	65	1,41	2,06	756 017	1	83 162	
MACM 2023 00002_1749868	j-23	66	1,86	1,61	1 891 858	3		
44534900_1751474	a-23	67	1,36	1,27	321 363	1	19 282	
SA-29-LOI-23-P_1729379	a-23	68	1,21	3,64	81 690	1	-7 352	
4102-2023-96_1758622	s-23	69	1,74	1,44	428 272	6		
44534730_1759916	s-23	70	1,13	1,40	138 180	1	-23 491	
2023-09-B_1762324_Lot 01	s-23	71	1,29	1,18	1 015 338	2		
2023-09-B_1762324_Lot 02	s-23	71	1,28	1,31	1 355 536	1	-27 111	
96900238_1768746	o-23	73	1,63	1,74	1 376 601	2		
QC-RAMQ-20230248_1768753	o-23	75	1,31	1,42	992 873	1	9 929	
89065_1773518	o-23	76	1,93	1,26	199 082	7		
44534835_1773262	n-23	81	1,41	1,02	166 269	7		
44536368_1779110_Lot 03	n-23	82	1,68	1,33	198 585	6		
44536368_1779110_Lot 02	n-23	82	1,38	1,42	73 550	1	5 884	
44536368_1779110_Lot 01	n-23	82	1,68	1,38	205 940	6		
95S10245_1781524_Lot 03	n-23	91	1,71	2,77	795 429	2		
95S10245_1781524_Lot 04	n-23	91	1,69	2,79	563 647	1	219 822	
95S10245_1781524_Lot 01	n-23	91	1,71	2,87	578 477	1	237 176	
95S10245_1781524_Lot 02	n-23	91	1,71	2,14	443 156	2		
AOP-0328_1787152	d-23	102	1,53	1,78	2 904 762	1	668 095	
H23-1217MJR_1798198	j-24	104	1,38	1,52	485 951	11		
700001791_1807016	f-24	106	1,57	1,61	176 382	2		
700001792_1808261	f-24	107	1,48	1,24	1 380 991	3		
202403_1816375	m-24	110	1,75	1,51	621 410	7		
SÉCURITÉ-2024-2027_1831158_Lot 2	m-24	112	1,24	1,43	143 463	1	-8 608	
SÉCURITÉ-2024-2027_1831158_Lot 1	m-24	112	1,24	1,43	173 894	1	-10 434	
2024-55-64_1849263	m-24	117	1,62	1,10	1 396 347	2		
					Somme		8 319 867,83	
					Somme avec seuil		9 042 486,83	

On constate aussi une amélioration dans les profits pour les contrats les plus récents, cela correspond aussi à une baisse du nombre de marges trop basses pour être pertinentes. Le modèle semble mieux saisir comment approcher la marge gagnante la plus haute possible, sans aller au plus bas pour gagner dans tous les cas. On note aussi que pour certains contrats avec plusieurs lots, les marges données ne sont pas toutes égales, ce qui montre bien la considération des caractéristiques techniques propres des contrats.

6.3.2 Comparaison avec le comportement de référence des Commissionnaires

On compare maintenant notre modèle au comportement de référence du CCCQ. Pour cela, nous nous basons sur 20 appels d'offres auxquels le CCCQ a participé entre le 01/09/2023 et le 01/04/2026. L'appel d'offres le plus ancien étudié considère 70 données antérieures et le plus récent en considère 181. Les résultats sont consignés dans le Tableau 6.3. Le rang du modèle est calculé en considérant la marge prédite comme remplaçant celle du CCCQ.

La colonne « Précision concurrents prédits » présente la précision avec laquelle notre outil a identifié des concurrents qui ont effectivement été présents lors de l'appel d'offres. Dans certains cas, le manque de données ne permet pas cette prédiction. En moyenne, l'outil atteint 39 % de bonnes prédictions.

Si l'on considère les contrats non pertinents, c'est-à-dire les contrats dont le modèle prédit une marge non profitable, seul un cas montre une défaveur du modèle par rapport au choix du CCCQ (le CCCQ gagne avec une marge à 2,69 contre 1,08 pour le modèle).

Sur l'ensemble, le modèle obtient un meilleur rang que le CCCQ dans 90 % des cas, cependant cela est à nuancer en comparant les profits obtenus. En termes de profit général, le modèle surperforme le CCCQ, notamment grâce à de gros gains réalisés sur les lots du contrat *2024-8023-50_20005431*. Sur le contrat *2024-8023-50_20005431_LOT 06 - Volet C* gagné dans les deux cas, le modèle permet une amélioration des profits du CCCQ d'environ 401 000 \$. Sur les autres contrats gagnés à la fois par le CCCQ et le modèle, le modèle accuse une perte de profit de 397 000 \$, ce qui annule le gain réalisé auparavant.

Si on ne considère que les appels d'offres où la marge donnée par le modèle semblait pertinente, le modèle obtient un profit total de 14 677 139 \$ contre 2 145 052 \$ pour le CCCQ. Cela est en partie grâce au gain de 6 contrats supplémentaires rapportant 12 305 118 \$. Sans ceux-ci les profits

sont équivalents avec 2 372 020 \$ pour le modèle contre 2 145 051 \$ pour le CCCQ. On notera qu'une analyse de sensibilité dans une plage raisonnable ($\pm 0,05$) du seuil de rentabilité conduit ici aux mêmes résultats.

6.4 Conclusion

L'évaluation globale de notre outil, menée à la fois sur ses capacités de prospection et de prédiction tarifaire, confirme sa pertinence en tant que système d'aide à la décision pour le CCCQ.

D'une part, le volet de prospection affiche des résultats très satisfaisants. L'algorithme *Entity Matching* s'avère robuste, avec un taux de concordance de 92 %, ce qui automatise et renforce grandement le repérage de l'historique des contrats. De plus, la capacité d'anticipation des renouvellements offre un avantage stratégique pour la préparation des offres, même si elle reste naturellement soumise aux aléas de publication et notamment aux options des contrats.

D'autre part, l'analyse du modèle de tarification met en lumière des constats cruciaux. Si le modèle algorithmique brut tend parfois à recommander des marges extrêmement compétitives allant jusqu'à la non-viabilité économique (en deçà du seuil de $\sim 0,3$), l'intégration d'un seuil de rentabilité par les analystes corrige efficacement ce biais. Sous ces conditions, le modèle surperforme globalement les décisions historiques du CCCQ. En obtenant un meilleur classement que la référence dans la plupart des scénarios comparatifs étudiés et en permettant de remporter des contrats majeurs.

Bien que certaines fonctionnalités disposent encore d'une marge d'amélioration (comme la prédiction exacte des concurrents à 39 %), le modèle démontre une excellente capacité d'apprentissage au fil du temps. En outre, notre solution ne doit pas être vue comme un remplaçant de l'expertise humaine, mais bien comme un puissant levier d'optimisation, capable de guider le CCCQ vers la maximisation de ses taux de victoire et de sa rentabilité globale.

Tableau 6.3 Résultat du modèle pour 20 AOs et confrontation avec la référence du CCCQ

Appel d'offres	Modèle (marge)	CCCQ (marge)	Dernier gagnant (marge)	Précision concurrents prédits	Rang CCCQ	Rang Modèle	Prix	Profit CCCQ	Profit Modèle
44544014_20097223	1,16	1,46	1,21	42 %	10	1	672,509		-94,151
AO-25-11-P-sp_20087874	1,08	2,69	2,69		1	1	138,092	191,593	-30,380
1000859_20087088	1,28	1,52	1,13	25 %	8	4	3,964,947		
999741629-99741630_20081991_Lot 02	1,07	1,40	1,36	21 %	3	1	23,097		-5,312
999741629-99741630_20081991_Lot 01	1,07	1,44	1,33	16 %	2	1	49,317		-11,343
25-20987_20078343	1,57	1,80	1,53	20 %	7	4	245,627		
2024/25-275_20052354	1,08	4,51	2,18	67 %	6	1	172,488		-37,947
2025-8023-20_20041772_LOT 16 - Volet A	1,50	1,61	1,61	37 %	3	2	12,039,234		
2025-8023-20_20041772_LOT 08 - Volet A	1,50	2,75	1,84	30 %	9	1	3,093,698		618,740
2025-8023-20_20041772_LOT 05 - Volet A	1,50	1,62	1,52	33 %	4	1	4,793,726		958,745
500955-2_20022357	2,55	2,73	2,60		6	2	2,054,924		
2024-569_20011888	1,41	1,72	1,72		1	1	65,404	27,754	7,194
2024-8023-50_20005431_LOT 06 - Volet C	1,60	1,54	1,61	38 %	1	1	6,729,792	1,617,398	2,018,938
2024-8023-50_20005431_LOT 05 - Volet B	1,46	1,54	3,82	54 %	2	1	24,359,194		3,897,471
2024-8023-50_20005431_LOT 04 - Volet B	1,46	1,54	3,81	54 %	2	1	22,780,720		3,644,915
2024-8023-50_20005431_LOT 04 - Volet A	1,60	1,62	1,60	54 %	2	1	10,617,491		3,185,247
2024-8023-50_20005431_LOT 03 - Volet C	1,62	1,54	1,34	46 %	5	6	4,597,974		
44535338_1772515	1,41	1,46	1,46		1	1	3,144,440	499,899	345,888
AOP-0328_1787152	1,52	1,81	1,78		3	1	2,904,761		639,047
44534730_1759916	1,09	1,57	1,40	50 %	6	1	138,179		-29,018
							Somme	2,336,645	15,108,035
							Somme avec seuil		15,316,186

CHAPITRE 7 Conclusion et perspectives

La revue de littérature menée a confirmé que, si la modélisation de la décision de soumission et de la stratégie de prix constitue un champ étudié depuis les travaux de Friedman (1956) et Gates (1967), l'intégration conjointe de l'extraction d'information textuelle, de la recherche de contrats similaires et de la modélisation tarifaire reste peu documentée, en particulier dans le secteur des services et plus spécifiquement celui de la sécurité. Notre contribution scientifique se situe précisément à cette intersection. Nous avons proposé un cadre intégré d'aide à la décision qui combine cinq éléments complémentaires : un module d'anticipation et de fouille historique fondé sur la résolution d'entité ; un module de valorisation des données textuelles s'appuyant sur une architecture de génération augmentée de récupération (*RAG*); un module de calcul de similarité entre contrats appris par renforcement de classement ; un modèle de tarification de type *Learning to Rank*, adapté à la rareté des données ; et un outil de visualisation interactif assurant la cohérence et l'utilisabilité de l'ensemble. L'application conjointe de ces composants permet une valorisation importante des données historiques et l'apport d'indicateurs systématiques et quantitatifs qui soutiennent les décisions des gestionnaires.

Au terme de ce travail, il convient de revenir sur les objectifs formulés au CHAPITRE 3. L'objectif général visait à améliorer le processus de réponse aux appels d'offres en valorisant les données historiques par l'intégration de méthodes d'intelligence artificielle et de valorisation des données. Cet objectif s'est décliné en trois objectifs spécifiques que nos travaux permettent aujourd'hui de considérer comme atteints à différents niveaux. Le premier, caractériser les variables et indicateurs décisionnels qui structurent les décisions de soumission, a été rempli par l'analyse du cas d'étude et la modélisation du processus (CHAPITRE 4), qui ont mis en évidence les indicateurs pertinents relatifs tant au contrat qu'à l'environnement concurrentiel, puis par leur extraction systématique au moyen de la résolution d'entité et de la génération augmentée de récupération (*RAG*). Le deuxième, déterminer quels modèles et approches issus de la littérature sont transposables au contexte spécifique du partenaire, a été traité par la revue systématique et l'analyse critique (CHAPITRE 2), qui ont conduit à retenir puis à assembler un ensemble cohérent d'approches : résolution d'entité; *RAG*; apprentissage de classement; et modèle de tarification *Learning to Rank*, tous adaptées à la rareté des données et aux spécificités de notre cas. Le troisième, adapter les approches retenues et valider leur viabilité en contexte réel en les appliquant aux données historiques de notre

partenaire, a été satisfait par le développement de l'outil intégré (CHAPITRE 5) et par les expérimentations menées sur cinq années d'historique (CHAPITRE 6), qui confirment la pertinence opérationnelle de l'ensemble au regard de la référence interne des Commissionnaires.

Sur le plan opérationnel, notre travail propose un outil intégré et utilisable, développé en Python et alimenté à la fois par les données ouvertes du SEAO et par les bases de données internes du partenaire. L'outil ne se substitue pas à l'expertise humaine, il l'enrichit. Il transforme la posture de prospection en offrant une vision unifiée des avis en cours et des renouvellements anticipés, automatise la lecture des devis techniques pour quantifier de manière systématique les besoins matériels d'un contrat, retrouve automatiquement l'historique des contrats par résolution d'entité, et propose une recommandation chiffrée de marge appuyée sur les contrats similaires et la dynamique récente du marché. Les expérimentations conduites confirment la pertinence de cette approche : l'algorithme *d'Entity Matching* atteint un taux de concordance très satisfaisant, le modèle de tarification se classe dans le trio de tête des soumissions dans 70 % des cas lorsqu'on se restreint aux marges économiquement viables, et il améliore le rang du CCCQ dans une très grande majorité des appels d'offres confrontés à la référence interne. Sous réserve d'une lecture experte des marges proposées et particulièrement lorsqu'elles tombent sous le seuil de viabilité économique, l'outil apporte un gain potentiel de profit substantiel, tout en réduisant l'effort manuel de prospection et de fouille des données.

Plusieurs limites doivent toutefois être reconnues. Tout d'abord, la base de données mobilisée pour l'entraînement et l'évaluation reste modeste. Cette rareté contraint le choix des architectures de modélisation et limite la finesse des analyses statistiques que l'on peut mener sur les performances. Par ailleurs, les indicateurs produits reposent sur des données historiques et présupposent donc une certaine stationnarité du marché, c'est-à-dire que les dynamiques passées demeureraient valables pour anticiper les décisions futures. Si cette hypothèse constitue une limite réelle, elle n'affecte pas la valeur des nombreuses analyses descriptives fournies par l'outil, qui restent pleinement pertinentes pour aider les gestionnaires à détecter un éventuel changement de paradigme contextuel et à réévaluer leurs décisions en conséquence. Ensuite, le modèle peut suggérer des marges en deçà du seuil de rentabilité économique : sans la médiation du gestionnaire, les recommandations seraient préjudiciables. Aussi, l'évaluation a été conduite de manière rétrospective sur l'historique des Commissionnaires, elle ne préjuge donc pas pleinement du comportement de l'outil dans une utilisation continue où ses propres recommandations alimenteraient les futures décisions et, par

effet de boucle, sa propre base d'apprentissage. Enfin, l'extraction par *RAG*, bien que validée qualitativement et calibrée sur la catégorie « uniformes », repose sur un dictionnaire de coûts élaboré avec l'aide d'experts, qui gagnerait à être étudié plus en profondeur. De plus, cette infrastructure et méthode de *RAG* pourrait être développée plus profondément afin d'automatiser entièrement le processus d'extraction des données techniques permettant ainsi l'élimination de la dernière tâche manuelle nécessaire à la constitution de la base de données.

À court terme, plusieurs pistes peuvent renforcer l'outil. L'enrichissement continu de la base de données interne, par la systématisation de l'archivage des dossiers de travail et la complétion rétroactive des contrats dont les pièces sont incomplètes, permettrait d'accroître la précision du modèle de similarité ainsi que du modèle de tarification. L'intégration d'un mécanisme explicite de gestion du seuil de rentabilité, ou la formulation du *Learning to Rank* sous contrainte de rentabilité minimale, permettrait par ailleurs d'éviter les recommandations non viables. La prédiction des concurrents pourrait aussi être reformulée en une tâche de modélisation séquentielle prenant en compte la trajectoire récente de chaque acteur sur le marché, plutôt qu'en agrégat statique mais cela nécessiterait alors plus de données sur chacun des concurrents.

À moyen terme, l'outil gagnerait à être déployé en conditions de production, avec un accompagnement adapté à la conduite du changement. Le suivi longitudinal de l'utilisation par les gestionnaires, de leurs validations, ajustements et rejets des recommandations, fournirait des données précieuses pour une boucle de rétroaction. Une étude d'impact, mesurant les variations des taux de victoire et de rentabilité avant et après déploiement, permettrait également d'objectiver le bénéfice opérationnel sur un horizon plus long.

À plus long terme, deux extensions paraissent particulièrement intéressantes. La première consiste à étendre la portée de l'outil à d'autres types de services (notamment ceux proposés par notre partenaire, tels que la cybersécurité, l'enquête, la surveillance, etc.) afin d'éprouver la généralisation du cadre méthodologique au-delà du secteur de la sécurité. La seconde concerne le passage d'une logique de réponse, contrat par contrat, à une logique de gestion de portefeuille d'appels d'offres, où le choix de soumission et la marge ne seraient plus optimisés indépendamment, mais en tenant compte des contraintes de capacité, des objectifs stratégiques et des risques agrégés du portefeuille. Cette ouverture rapprocherait notre travail des approches récentes de gestion de

portefeuille de projets et offrirait au CCCQ, ou à toute organisation similaire, un outil cohérent, de la veille amont jusqu'à la décision stratégique.

En définitive, ce mémoire propose une démonstration concrète qu'il est possible, même avec un volume de données modeste et une grande hétérogénéité documentaire, de construire un outil quantitatif d'aide à la décision cohérent par rapport à une référence experte sur la plupart des indicateurs étudiés. La valeur de cette contribution réside autant dans l'outil lui-même que dans la démarche : montrer comment des techniques de traitement automatique du langage, d'apprentissage de classement et de visualisation peuvent être articulées de manière modulaire pour appuyer un processus métier complexe, sans pour autant en évincer l'expertise humaine. Nous espérons que cette articulation pourra inspirer des travaux futurs, tant dans le secteur des services de sécurité que dans d'autres contextes de réponse aux appels d'offres.

RÉFÉRENCES

- À propos de Commissionnaires.* (2026). Commissionnaires du Québec.
<https://commissionnairesquebec.ca/a-propos/>
- Ballesteros-Pérez, P., & Skitmore, M. (2017). On the distribution of bids for construction contract auctions. *Construction Management and Economics*, 35(3), 106-121.
<https://doi.org/10.1080/01446193.2016.1247972>
- Biruk, S., Jaśkowski, P., & Czarnigowska, A. (2017). Modeling Contractor's Bidding Decisions. *Procedia Engineering, 7th International Conference on Engineering, Project, and Production Management*, 182, 91-98. <https://doi.org/10.1016/j.proeng.2017.03.125>
- Blessing, L. T. M., & Chakrabarti, A. (2009). *DRM, a Design Research Methodology*. Springer.
<https://doi.org/10.1007/978-1-84882-587-1>
- Burges, C., Shaked, T., Renshaw, E., Lazier, A., Deeds, M., Hamilton, N., & Hullender, G. (2005). Learning to rank using gradient descent. *Proceedings of the 22nd international conference on Machine learning, ICML '05*, 89-96. <https://doi.org/10.1145/1102351.1102363>
- Business Process Model and Notation (BPMN), Specification Version 2.0. (2011). *Object Management Group*. <https://www.omg.org/spec/BPMN/>
- Carr, R. I. (1982). General Bidding Model. *Journal of the Construction Division*, 108(4), 639-650.
<https://doi.org/10.1061/JCCEAZ.0001070>
- Charbel, G., H. Assaad, R., Qiao, Y., & Labi, S. (2025). Predicting the Level of Competition and Determining Optimal Bidding Strategies for Bundled Projects : Integrating Machine-

- Learning Algorithms and Probabilistic Modeling. *Journal of Construction Engineering and Management*, 151, 04025178. <https://doi.org/10.1061/JCEMD4.COENG-15634>
- Chen, T., & Guestrin, C. (2016). XGBoost : A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, KDD '16*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Chisala, M. L. (2017). Quantitative Bid or No-Bid Decision-Support Model for Contractors. *Journal of Construction Engineering and Management*, 143(12), 04017088. [https://doi.org/10.1061/\(ASCE\)CO.1943-7862.0001407](https://doi.org/10.1061/(ASCE)CO.1943-7862.0001407)
- Choi, S.-W., & Lee, E.-B. (2022). Contractor's Risk Analysis of Engineering Procurement and Construction (EPC) Contracts Using Ontological Semantic Model and Bi-Long Short-Term Memory (LSTM) Technology. *Sustainability*, 14(11), 6938. <https://doi.org/10.3390/su14116938>
- Christodoulou, S. (2010). Bid mark-up selection using artificial neural networks and an entropy metric. *Engineering, Construction and Architectural Management*, 17(4), 424-439. <https://doi.org/10.1108/09699981011056600>
- Chua, D. K. H., Li, D. Z., & Chan, W. T. (2001). Case-Based Reasoning Approach in Bid Decision Making. *Journal of Construction Engineering and Management*, 127(1), 35-45. [https://doi.org/10.1061/\(ASCE\)0733-9364\(2001\)127:1\(35\)](https://doi.org/10.1061/(ASCE)0733-9364(2001)127:1(35))
- Classification universelle normalisée des produits et des services des Nations Unies (UNSPSC)*. (2026). <https://www.ungm.org/public/unspsc>
- Commissionnaires du Québec. (2026). *À propos de Commissionnaires*. Commissionnaires du Québec. <https://commissionnairesquebec.ca/a-propos/>

- Cusumano, L., Rempling, R., Jockwer, R., Saraiva, R., Granath, M., Olsson, N., & Okazawa, S. (2022). *Natural language processing as work support in project tendering* (p. 549-550). <https://doi.org/10.1201/9781003348450-258>
- Cusumano, L., Saraiva, R., Rempling, R., Jockwer, R., Olsson, N., & Granath, M. (2022). *Intelligent building contract tendering – potential and exploration*. 1902-1909. <https://doi.org/10.2749/prague.2022.1902>
- Dawood, N. N. (1994). Developing an integrated bidding management expert system for the precast concrete industry. *Building Research & Information*. <https://doi.org/10.1080/09613219408727357>
- Dictionnaire de la comptabilité et de la gestion financière, version 1.2*. (2006). <https://vitrinelinguistique.oqlf.gouv.qc.ca/fiche-gdt/fiche/501033/appel-doffres> (Édition originale Institut Canadien des Comptables Agréés)
- Faraji, A., Rashidi, M., Eftekhari, N. A., Perera, S., & Mani, S. (2022). A Bid/Mark-Up Decision Support Model in Contractor's Tender Strategy Development Phase Based on Project Complexity Measurement in the Downstream Sector of Petroleum Industry. *Journal of Open Innovation: Technology, Market, and Complexity*, 8(1), 33. <https://doi.org/10.3390/joitmc8010033>
- Friedman. (1956). *A Competitive-Bidding Strategy*. <https://doi.org/10.1287/opre.4.1.104>
- Gates. (1967). *Bidding Strategies and Probabilities*. <https://doi.org/10.1061/JCCEAZ.0000192>
- Iida, H., & Okazaki, N. (2022, novembre 8). *Unsupervised Domain Adaptation for Sparse Retrieval by Filling Vocabulary and Word Frequency Gaps*. arXiv.Org. <https://arxiv.org/abs/2211.03988v1>

- Kim, Y., Lee, J., Lee, E.-B., & Lee, J.-H. (2020). Application of Natural Language Processing (NLP) and Text-Mining of Big-Data to Engineering-Procurement-Construction (EPC) Bid and Contract Documents. *2020 6th Conference on Data Science and Machine Learning Applications (CDMA)*, 123-128. <https://doi.org/10.1109/CDMA47397.2020.00027>
- Król, R., Bączkiewicz, A., & Wątróbski, J. (2024). Application of Machine Learning Algorithms for Identification of Key Criteria Groups in Public Tendering Proceedings in Poland. *Lect. Notes Networks Syst., 1079 LNNS*, 331-341. https://doi.org/10.1007/978-3-031-66761-9_26
- Loi sur les décrets de convention collective, Acte jurid. N° RLRQ, Chapitre D-2, règle1 (2026). <https://www.legisquebec.gouv.qc.ca/fr/document/rc/D-2,%20r.%201>
- Lops, P., Di Ciano, M., Lopane, N., Siciliani, L., Taccardi, V., Ghizzota, E., & Semeraro, G. (2022). *AI-based Decision Support Systems for the Management of E-procurement Procedures*. CEUR-WS. <https://ricerca.uniba.it/handle/11586/415812>
- Lu, W., Chen, K., Qiao, R., & Sun, X. (2025, septembre 15). *HiChunk : Evaluating and Enhancing Retrieval-Augmented Generation with Hierarchical Chunking*. arXiv.Org. <https://arxiv.org/abs/2509.11552v3>
- Malatesta, B., & Mancini, M. (2026). AI-Enabled Contractual Knowledge and Risk Governance in EPC Projects : A Conceptual Framework and Research Agenda. In F. Cantoni, F. Di Maddaloni, P. Di Nauta, & M. Arcuri (Éds.), *Bridging Public and Private Interests in Megaprojects : Practical and Theoretical Implications* (p. 209-232). Springer Nature Switzerland. https://doi.org/10.1007/978-3-032-19235-6_13


- Mandikal, P., & Mooney, R. (2024, janvier 8). *Sparse Meets Dense : A Hybrid Approach to Enhance Scientific Document Retrieval*. arXiv.Org. <https://arxiv.org/abs/2401.04055v1>
- Mencia, E. L., Holthausen, S., Schulz, A., & Janssen, F. (2013). *Using Data Mining on Linked Open Data for Analyzing E-Procurement Information*.
- Molina-Miranda, M. F., Acaro, X., Molina, M., Quiñonez, M., Alvarez, G., Fernandez-Olivares, J., & Pérez, R. (2023). Application of explainable artificial intelligence to analyze basic features of a tender. *2023 3rd International Conference on Electrical, Computer, Communications and Mechatronics Engineering (ICECCME)*, 1-6. <https://doi.org/10.1109/ICECCME57830.2023.10253063>
- Moriyani, M. A., Le, C., Le, T., & Pirim, H. (2026). Beyond One-Size-Fits-All : A Novel Data-Driven Framework for Quantifying Bidding Competition Intensity in Highway Design-Bid-Build Contracts. *Journal of Construction Engineering and Management*, 152(3), 04026006. <https://doi.org/10.1061/JCEMD4.COENG-17163>
- Moselhi, O., & Hegazy, T. (1993). Markup estimation using neural network methodology. *Computing Systems in Engineering, Civil-Comp Artificial Intelligence*, 4(2), 135-145. [https://doi.org/10.1016/0956-0521\(93\)90039-Y](https://doi.org/10.1016/0956-0521(93)90039-Y)
- Mosser, J. (2020). *Cartographie 4.0 pour la transformation numerique des processus* [Mémoire de maîtrise]. Polytechnique Montréal.
- Mosser, J., Pellerin, R., Bourgault, M., Danjou, C., & Perrier, N. (2022). GRMI4.0 : A guide for representing and modeling Industry 4.0 business processes. *Business Process Management Journal*, 28(4), 1047-1070. <https://doi.org/10.1108/BPMJ-12-2021-0758>

- Padhy, J., Jagannathan, M., & Kumar Delhi, V. S. (2021). Application of Natural Language Processing to Automatically Identify Exculpatory Clauses in Construction Contracts. *Journal of Legal Affairs and Dispute Resolution in Engineering and Construction*, 13(4). [https://doi.org/10.1061/\(ASCE\)LA.1943-4170.0000505](https://doi.org/10.1061/(ASCE)LA.1943-4170.0000505)
- Park, M.-J., Lee, E.-B., Lee, S.-Y., & Kim, J.-H. (2021). A Digitalized Design Risk Analysis Tool with Machine-Learning Algorithm for EPC Contractor's Technical Specifications Assessment on Bidding. *Energies*, 14(18), 5901. <https://doi.org/10.3390/en14185901>
- Porter, M. (2008). The Five Competitive Forces That Shape Strategy. *Harvard business review*, 86, 78-93, 137.
- PyMuPDF. (2026). *Pymupdf/pymupdf4llm* [Python]. <https://github.com/pymupdf/pymupdf4llm> (Édition originale 2024)
- Raini, R. (2024). *LARGE LANGUAGE MODELS IN LEGAL DUE DILIGENCE*. Addleshaw Goddard.
- Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework : BM25 and Beyond. *Found. Trends Inf. Retr.*, 3(4), 333-389. <https://doi.org/10.1561/15000000019>
- Sadoune, I., Joanis, M., & Lodi, A. (2023). Implementing a Hierarchical Deep Learning Approach for Simulating multilevel Auction Data. *Working Papers*, Article 2023s-23. <https://doi.org/10.54932/LQOG8430>
- Siciliani, L., Taccardi, V., Basile, P., Di Ciano, M., & Lops, P. (2023). AI-based decision support system for public procurement. *Information Systems*, 119, 102284. <https://doi.org/10.1016/j.is.2023.102284>


- Simões, A., Madureira, R., & Amorim, M. (2023). *Unlocking the Potential of Procurement 4.0 : The Role of Digitalization, Industry 4.0, and Information Systems*. 1-6.
<https://doi.org/10.23919/CISTI58278.2023.10211830>
- Skitmore, M. (2002). Predicting the probability of winning sealed bid auctions : A comparison of models. *Journal of the Operational Research Society*, 53.
<https://doi.org/10.1057/palgrave/jors/2601236>
- Skitmore, M. (2004). Predicting the probability of winning sealed bid auctions : The effects of outliers on bidding models. *Construction Management and Economics*, 22(1), 101-109.
<https://doi.org/10.1080/0144619042000186103>
- Skitmore, M. (2014). Generalised gamma bidding model. *Journal of the Operational Research Society*, 65. <https://doi.org/10.1057/jors.2013.18>
- Skitmore, M., Pettitt, A., & McVinish, R. (2007). Gates' Bidding Model. *Journal of Construction Engineering and Management*, 133. [https://doi.org/10.1061/\(ASCE\)0733-9364\(2007\)133:11\(855\)](https://doi.org/10.1061/(ASCE)0733-9364(2007)133:11(855))
- Stargazers · explosion/spaCy*. (2026). GitHub. <https://github.com/explosion/spaCy>
- Sturm, N. F., Candia, C., Damásio, B., & Pinheiro, F. L. (2026). Augmenting Firm Diversification Behavior Prediction with Graph Embeddings. *Stud. Comput. Intell.*, 1265 SCI, 111-122.
https://doi.org/10.1007/978-3-032-16723-1_10
- Tirmizi, S. A. A., & Arif, F. (2022). Conceptual Approach for the Use of Artificial Intelligence for Contractual Risk Assessment in Infrastructure Projects. *Engineering Proceedings*, 22(1).
<https://doi.org/10.3390/engproc2022022012>

- Vásquez, J. C. G., & Kumral, M. (2025). Artificial neural networks and support vector machines for more accurate cost estimation in underground mining : A contractor's viewpoint. *Machine Learning with Applications*, 21, 100689. <https://doi.org/10.1016/j.mlwa.2025.100689>
- Young-Hun, K., & Gitae, K. (2024). *View of Analysis Bidding Price Analysis Using K-Means Cluster, Machine Learning, And Deep Learning in Public Institution Competitive Bidding : Targeting Service Projects in The Chungcheong Region*. <https://nanonntp.com/index.php/nano/article/view/635/539>
- Zhang, L., Ning, Y., & Zhou, S. (2026). Automated multi-label classification of risk clauses in construction contracts using GPT-driven data augmentation. *Automation in Construction*, 181, 106599. <https://doi.org/10.1016/j.autcon.2025.106599>


ANNEXE A PROCESSUS DE RÉPONSE GÉNÉRAL (AS-IS)




ANNEXE B PROCESSUS DE RÉPONSE (AS-IS) PARTIE 1 : PRÉANALYSE



ANNEXE C PROCESSUS DE RÉPONSE (AS-IS) PARTIE 2 : ANALYSE




ANNEXE D PROCESSUS DE RÉPONSE (AS-IS) PARTIE 3 : SCÉNARIO FINANCIER

ANNEXE E MÉTHODE DE RETRIEVAL SPARSE + HIERARCHIE

2- ENRICHED SPARSE EMBEDDINGS

1- CHUNKING



C.03 Ressources matérielles

Le PRESTATAIRE DE SERVICES doit posséder tous les équipements, les outils et les véhicules selon la nature du mandat et les exigences du présent Devis. Ceux-ci doivent être de bonne qualité et en bon état de marche, à cet effet le PRESTATAIRE DE SERVICES...

Texte Brut

spaCy

['c.03', 'ressource', 'matériel', 'prestataire', 'service', 'posséder', 'équipement', 'outil', 'véhicule', 'nature', 'mandat', 'exigence', 'présent', 'devis', 'bon', 'qualité', 'bon', 'état', 'marche', 'prestataire', 'service' ...]

Tokens Base



DOMAIN VOCABULARY = {
'uniforme': ['vêtement', 'tenue', 'chemise', ...],
'véhicule': ['voiture', 'suv', 'marquage', ...],
'équipement': ['matériel', 'outils', 'talkie', 'walkie-talkie', ...]}

['c.03', 'ressource', 'matériel', 'prestataire', 'service', 'posséder', 'équipement', 'outil', 'véhicule', 'nature', 'mandat', 'exigence', 'présent', 'devis', 'bon', 'qualité', 'bon', 'état', 'marche', 'prestataire', 'service', 'équipement', ...]

Tokens enrichi

$$Token_{enrichi} = Token_{base} \cup \{ D \mid \exists t \in Token_{base} \text{ si } t \in V_D \} \text{ , avec } V_D \text{ le dictionnaire du mot-clé } D$$

3- RETRIEVAL

QUERY (Q)	Le prestataire doit-il fournir de l'équipement ?	['prestataire', 'doit', 'fournir', 'équipement']
CHUNK (C)	Le gardien doit apporter sa lampe mag-lite et sa radio.	['gardien', 'doit', 'apporter', 'lampe', 'mag-lite', 'radio', 'équipement', 'équipement']

3.1 Text Scoring Chunk

Pour une requête Q et un chunk C:

$$Score(C, Q) = \sum_{i=1}^n IDF(q_i) \cdot \frac{f(q_i, C) \cdot (k_1 + 1)}{f(q_i, C) + k_1(1 - b + b \frac{|C|}{avgdl})}$$

$$IDF(q_i) = \ln \left(\frac{N - n(q_i) + 0,5}{n(q_i) + 0,5} + 1 \right)$$

$f(q_i, C)$ = Nombre d'apparition du mot q_i dans le chunk C
 C = Longueur du chunk C
 $avgdl$ = Longueur moyenne des documents du corpus
 N = Nombre de document dans le corpus
 $n(q_i)$ = Nombre de documents contenant le mot q_i
 $b = 0,75$ (paramètre de fonction)
 $k_1 \in [1,2; 2,0]$ (paramètre d'optimisation)

→ TF-IDF + Saturation des termes + Longueur des documents

- IDF : Facteur de rareté d'un mot
- $f(q_i, C) \cdot (k_1 + 1)$: Fréquence du mot, introduction d'une saturation avec k_1 (mot rare = poids important)
- $1 - b + b \frac{|C|}{avgdl}$: Normalisation de la longueur du document (limite le poids de la répétition d'un mot)
- (booste le poids des documents plus petits)

3.2 Hierarchical Scoring Chunk

Pour une requête Q et un chunk C:

$$S_{base}(C) = Score(C, Q)$$

$$S_{parent}(C) = \begin{cases} S_{base}(P(C)) & \text{si } P(d) \neq \emptyset \\ S_{base}(C) & \text{sinon} \end{cases}$$

$$S_{enfants}(C) = \begin{cases} \max_{E \in E(C)} (S_{base}(E)) & \text{si } E(C) \neq \emptyset \\ S_{base}(C) & \text{sinon} \end{cases}$$

$$S(C) = S_{base}(C) \left(\frac{S_{parent}(C) + S_{enfant}(C)}{2} \right)$$

$$K = \{ \text{Le titre du chunk C contient un mot du dictionnaire } V_D \}$$

3.3 Final Retrieval

$$Retrieved = \underbrace{\{ c \mid S(c) \geq \tau \cdot \max_{c \in C} S(c) \}}_{\text{Sparse retrieval}} \cup \underbrace{\{ k \mid S(k) \geq \beta \cdot \max_{c \in C} S(c) \text{ si } k \in K \}}_{\text{Naive retrieval}}$$

Avec τ et β des seuils définis